

自然语言处理总结

https://blog.csdn.net/qg_39328436/article/details/122285444

Attention 是什么？其在 NLP 领域有什么应用？优势是什么？

Attention 是一种注意力机制，用于让模型在处理输入序列时，动态地关注输入中的某些部分，而忽略其他部分，它通过计算序列中每个元素与目标输出的相关性分数，即注意力权重，来决定哪些输入部分对当前任务最重要。

- 机器翻译：Transformer 中的自注意力机制；
 - 文本摘要：提取文本中最重要的信息；
 - 问答系统：关注问题相关的文本片段；
 - 图像字幕：结合图像与语言关注特定图像区域生成描述。
1. 捕捉长距离依赖关系：相比于 RNN，Attention 可以更有效地捕捉输入序列中远距离的依赖；
 2. 算法并行化计算：特别是 Transformer 中的 Attention，计算可以高效并行化；
 3. 增加模型的可解释性：Attention 提供了直观可视化的权重，方便观察模型重点关注的输入部分。


指针网络与指针生成网络的异同

- 都使用了注意力机制，能够在输入中选择重要部分；
- 指针网络用于输出索引位置，而指针生成网络既可以选择输入的词，也可以从词汇表生成新词；
- 指针生成网络更复杂，结合了生成机制与复制机制。

$$\Pr(w) = p_{\text{generate}} \cdot p_{\text{vocabulary}}(w) + (1 - p_{\text{generate}}) \sum_{i:w_i=w} a_i^t$$

2. 指针生成器网络模型 (pointer-generator network)

问题：如何将生成网的词概率分布与指针网词的概率分布融合



融合方法

在时刻 t 由Att向量 h_t^* ，decoder状态向量 s_t 和decoder输入 x_t 共同计算生成概率门控 p_{gen} (软门)

$$p_{gen} \in [0,1]$$

$$p_{gen} = \sigma(w_{h^*}^T h_t^* + w_s^T s_t + w_x^T x_t + b_{ptr})$$

其中, w_{h^*} , w_s , w_x , b_{ptr} 是参数

融合后得到最终概率分布

$$P(w) = p_{gen} P_{vocab}(w) + (1 - p_{gen}) \sum_{i:w_i=w} a_i^t$$

注：“+” 是进行维度的扩充并加和

维特比算法

算法原理要背下来

(2) HMM解码问题

解：用Viterbi 搜索算法

	晴天	阴天	下雨
晴天	0.50	0.25	0.25
阴天	0.375	0.25	0.375
下雨	0.25	0.125	0.625


	干	稍干	潮湿	湿润
晴天	0.60	0.20	0.15	0.05
阴天	0.25	0.25	0.25	0.25
下雨	0.05	0.10	0.35	0.50

$\pi = (1, 0, 0)$

Viterbi 搜索算法

1. 初始化： $\delta_1(i) = \pi_i b_i(O_1)$, $\phi_1(i) = 0$, $1 \leq i \leq N$
2. 递归： $\delta_t(j) = [\max_{1 \leq i \leq N} \delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
 $\phi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) a_{ij}] b_j(O_t)$, $2 \leq t \leq T, 1 \leq j \leq N$
3. 终结： $p^* = \max_{1 \leq i \leq N} [\delta_T(i)]$, $q_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$
4. 路径回溯： $q_t^* = \phi_{t+1}(q_{t+1}^*)$, $t = T-1, T-2, \dots, 1$


此时不求和，只找出最大值即可



(干燥、潮湿、湿润)，最可能的天气序列：(晴、雨、雨)

模型结构：

输出层： $y^* = \underset{\tilde{y} \in Y_X}{\operatorname{argmax}} s(X, \tilde{y})$.



预训练第三范式和预训练第四范式异同

- 预训练第三范式为“预训练 + 精调”范式；
- 预训练第四范式为“预训练 + 提示 + 预测”范式；
- 参数调整：第三范式需要对下游任务的模型参数进行精调，第四范式不调整模型参数，通过提示控制输入实现任务适配；
- 训练成本：第三范式每个任务需要精调，训练成本较高，第四范式不需要任务精调，直接用预训练模型推断，成本低；
- 性能表现：第三范式对于任务数据充足的场景，精调性能通常优于提示方法，第四范式在数据不足场景下，提示方法可以更快部署，实现更高的效果；
- 灵活性：第三范式每次训练生成专属任务模型，适合特定任务优化，第四范式模型泛化能力强，可以快速适配多种任务。

RNN 与 DNN 相比有什么优势

- 适合处理序列数据：RNN 天然能够处理变长输入序列，捕获上下文信息；
- 记忆历史信息：通过隐藏状态能够记忆之前的输入，建模长短依赖关系；
- 动态序列建模：在生成任务中，RNN 能逐步生成序列，不需要固定输入长度。

GPT 与 BERT 异同

- 相同点：两者都是用 Transformer 架构，都使用了自注意力机制来捕获序列的上下文依赖；
- 不同点：
 - GPT 只使用了解码器部分，用于生成，BERT 只使用了编码器部分，用于词编码；
 - GPT 使用了自回归语言模型预测下一个词，BERT 使用掩码语言模型预测掩码的词语；

- GPT 为单项输入，BERT 为双向输入。

词向量的特点是什么？在 NLP 领域有什么价值？

词向量的特点：

- 稠密性：词向量是低维稠密向量，相较于传统的独热编码，更高效；
- 语义相似性：相似词的向量在嵌入空间中距离更近；
- 可训练性：词向量是通过模型（譬如 Word2Vec）从大规模语料中学习得到的。

在 NLP 领域的价值：

- 降低维度：将高维的离散词表转化为低维稠密向量，减少计算复杂度；
- 捕获语义关系：词向量能够反映词的语义相似性和上下文关系；
- 迁移学习：预训练的词向量可以作为多种 NLP 任务（如分类、命名实体识别）的基础，提升下游任务性能；
- 丰富上下文信息：通过上下文训练的动态词向量（如 BERT）进一步捕获词的多义性和上下文依赖性。

自然语言处理范式变迁

- 第一范式：特征工程 + 概率统计算法
- 第二范式：自动获取表征，端到端分类
- 第三范式：预训练 + 精调范式
- 第四范式：预训练 + 提示 + 预测范式
- 第五范式：大模型

梯度消失的原因

在误差反向传播时，每一层都要乘以激活函数的导数，若导数值小于 1，将导致误差越来越小，直至消失，如果导数过大，则会发生梯度爆炸。

激活函数的作用

增强网络表达能力，加入非线性因素。需要连续可导，激活函数和导函数简单，导函数值域范围合理

随机梯度下降与梯度下降区别

每次参数更新的数据量不同。

Attention 机制的输入

- Query 查询向量
- Key 键向量
- Value 值向量

常见的损失函数

- 绝对值损失
- 平方损失
- 交叉熵损失

注意力机制的本质

加权求和

常见梯度下降算法

- 梯度下降
- 随机梯度下降
- Min-Batch 梯度下降

DNN 训练参数的方法

梯度下降

可能导致梯度消失的激活函数

- Sigmoid
- tanh

CNN 结构

- 卷积层
- 池化层
- 全连接层交叉堆叠

CNN 结构特性

- 局部连接
- 参数共享
- 时空次采样

卷积层的作用

通过卷积操作减少参数。

池化层的作用

通过下采样减少网络规模，有助于防止过拟合，提供模型泛化能力。

全连接层

将池化层单元扁平化，即 flatten 函数，变成特征向量。

RNN 的参数训练方法

BPTT 随时间反向传播

Attention 中普通模式和键值对模式异同

普通模式将输入信息直接作为键和值，键值对模式下“键”用于计算注意力分布，“值”用于生成最终的输出。

Prompt 的核心思想是

将输入文本转换为模型可以理解的形式。

指针网络解决了什么问题

传统编码-解码架构输出词表大小固定，无法根据输入情况动态变化的问题

指针-生成网络解决了什么问题

输出词表与输入词表相同，无法处理输出需要产生输出词表以外词的情况

拷贝网络解决了什么问题

遇到词表以外的词，出现表达不准确的问题，对输入中的生僻字直接拷贝到输出序列中

Prompt 的两种形式

- 完形填空
- 前缀提示

改变任务形式利用预训练模型完成任务

输入序列 (x1x2x3x4x5)

模型	输入	输出	训练方法
CNN	序列: $(x_1x_2x_3x_4x_5)$	输出序列 $(x_1x_2x_3x_4x_5)$ 及 x_i 的概率分布	BP反向传播
RNN	序列: $< start > (x_1x_2x_3x_4)$	序列 $(x_1x_2x_3x_4x_5)$, RNN输出融合了历史记忆信息 $p(x_3 x_2) = p(x_3 x_1x_2)$	BPTT
统计语言模型	序列: $(x_1x_2x_3x_4x_5)$	序列 $(x_1x_2x_3x_4x_5)$ 概率, 或者为下一个词条件概率分布 $P(x_6 x_1x_2x_3x_4x_5)$	最大似然估计
神经语言模型	序列: $(x_1x_2x_3x_4x_5)$	下一个词条件概率分布 $P(x_6 x_1x_2x_3x_4x_5)$ 或者为序列的联合概率分布	BP+交叉熵
C&W	序列: $(x_1x_2x_3x_4x_5)$	输入序列 $(x_1x_2x_3x_4x_5)$ 的嵌入表示 输出序列的标量得分 $score(x_1x_2x_3x_4x_5)$	
CBOW	序列: $(x_1x_2x_3x_5)$	输出目标词 x_4 , 概率最大的目标词	BP+交叉熵

Skip-Gram	序列: (x_3)	输出预测的上下文概率 预测窗口为2输出序列 $(x_1x_2x_4x_5)$ 预测窗口为1输出序列 (x_2x_4) 概率最大	BP+交叉熵
Seq2Seq	序列: $(x_1x_2x_3x_4x_5)$	序列: $(x_1x_2...x_n)$	BP+交叉熵
Transformer	序列: $(x_1x_2x_3x_4x_5)$	输出为变长的翻译序列 $(y_1y_2y_3y_4)$	BP+交叉熵
Bert	序列: $(\langle cls \rangle x_1x_2x_3x_4x_5)$	输出为每个词的 <i>Embedding</i>	BP+下句预测+遮掩语言模型
GPT	序列: $(\langle bos \rangle x_1x_2x_3x_4x_5)$	具体输出看任务类型: 下一个词条件概率分布 $P(x_6 x_1x_2x_3x_4x_5)$ 完整的生成序列 $(x_6x_7x_8...x_n)$	BP+自回归

EMLO

学习深层的上下词表示知识，并用此来更好地增强各类 NLP 任务

什么是软注意力

选择的信息是所有输入信息在注意力分布下的期望。

什么是硬注意力

只关注到某一个位置上的信息。

什么是 BERT

BERT 通过使用双向 Transformer 编码器来捕捉文本中单词的上下文信息。

什么是 BART

BART 是一个用来预训练 Seq2Seq 模型的去噪自编码器，它通过在输入序列中加入随机噪声函数，并利用 Seq2Seq 结构从损坏的文本中重构原始文本来训练模型。BART 采用了一种编码-解码架构，编码器部分是双向的，类似于 BERT，可以捕捉输入文本的上下文信息，解码器部分是自回归的，类似于传统的序列生成模型，譬如 GPT，可以逐步生成输出序列。

GPT

生成式预训练，第一阶段预训练，第二阶段微调，ELMO 模型的基本框架采用双向 LSTM，而 GPT 采用 Transformer Decoder 结构。

CRF 条件随机场

CRF 能够对整个序列进行全局优化，而不是单独地对每个元素进行标注，会考虑整个序列的上下文信息，使得标注结果更加一致合理。

生成任务中常用的评价指标

BLEU、ROUGE

机器学习三要素

模型、策略、算法

BART 中为什么要使用位置嵌入

核心原因在于其底层的 Transformer 架构本身不具备处理序列顺序的能力，在计算注意力分数时，模型只关注 token 之间的相互关系，即语义相似度，而完全忽略了它们在句子中的位置，使用位置嵌入是为了打破自注意力机制的对称性。

Seq2Seq 序列生成模型的三种类型

- 生成式
- 选择式
- 选择-生成式

隐式马尔可夫链研究的三大问题

- 评估问题
- 解码问题
- 学习问题

隐式马尔可夫链的五元组

- 状态序列
- 观察序列
- 状态转移矩阵
- 发射矩阵
- 初始化状态

Transformer 在训练过程中采用什么技术实现并行操作

Mask 掩码技术

Mask 有什么作用，有哪几种

Mask 通过对某些值进行遮盖，使其不产生效果，有两种机制：

- Padding Mask：使不定长序列可以按定长序列统一并行操作
- Sequence Mask：防止标签泄露，只在 decoder 中的自注意力中

文本匹配常用的建模方法

- 基于表示，双塔模型，分别对 text 1 合 text 2 独立编码词向量，再计算两者的余弦相似度
- 基于交互，交互模型，一个词一个词的进行对比，通过 Attention 机制捕捉词之间的信息

什么是曝光偏差

在文本生成或机器学习模型中，模型生成的分布与真实数据分布并不严格一致，由于训练和推断阶段使用的输入分布不一致而导致的系统性误差，通俗来讲，是由于“训练时总是看标准真值”和“测试时只能靠自己”之间的不一致，导致模型在实际生成文本时容易步步错。可通过 Scheduled Sampling 在训练的过程中混合使用真实数据和生成数据训练。

什么是 BPE 算法，简要概述其工作原理

字节对编码算法是一种用于文本处理的子词分割算法，其核心思想是通过迭代合并频率最高的字符对，逐步构建一个更紧凑的词汇表。

- 第一步将语料库中所有单词拆分为字符序列，并统计每个单词出现的概率
- 第二步统计语料中所有相邻字符对出现的频率
- 第三步找到出现频率最高的字符对，将其合并成一个新的子词，并加入词表
- 第四步循环迭代重复上述步骤，在新的语料中，继续统计相邻对的频率，再次合并最高频的字符对
- 第五步直到词表达达到预设大小，或者没有可合并的字符对终止迭代

Transformer 实现并行处理所用到的技术有哪些

- 自注意力机制并行：传统的 RNN 是必须按照顺序处理序列，而自注意力机制允许模型同时看到输入序列中的所有位置，并且通过矩阵乘法运算，一次性计算出序列中所有词之间的依赖关系，适合在 GPU 上并行
- 位置编码并行：由于自注意力机制是并行处理所有词的，模型本身并没有像 RNN 那样天然的顺序或时间概念，因此需要注入顺序信息，为在并行处理的同时保留序列的顺序信息，预先定义好正弦余弦函数学习出来，并且不依赖前一个时间步计算，因此可以在预处理阶段并行完成
- 多头注意力并行：Transformer 不仅仅计算一次 Attention，而是并行多次计算，所有词嵌入向量子空间并行，分别关注输入序列的不同特征子空间，例如一个头关注语法结构，另一个头关注语义关联，这些头是异步计算的，最后再拼接起来
- 前馈神经网络并行：即前一个词的 FNN 计算不需要等待后一个词的结果，也不依赖于它，这使得这一层的计算可以完美在所有位置上并行化，这个 FNN 对序列中每个位置是独立且相同地应用的
- 在训练时我们已经知道正确的目标输出序列，因此不需要像推理那样生成一个词后再生成下一个，并且掩码注意力机制，可以在一次前向传播中就能计算出所有位置的损失值，不需要像 RNN 那样按照时间步展开 BPTT

神经网络语言模型存在的问题，使用 RNN + 词向量的方式是如何解决这些问题的

- 固定窗口限制的问题：神经网络语言模型是一个基于 N-gram 思想的模型，它只能接收固定长度的前 $n - 1$ 个词作为输入，这意味着模型无法捕捉超过这个窗口长度的长距离依赖；
- 参数数量与窗口大小相关的问题：为了获得更长的上下文，必须增加输入窗口的大小 n ，在全连接层中，输入层的参数矩阵大小会随着窗口大小线性增长，导致计算量急剧增加，难以训练；

- 无法处理变长序列的问题：神经网络语言模型要求输入必须是固定维度的，对于长度不一的自然语言句子，处理起来不够灵活，通常需要截断或填充。
- RNN 结合词向量通过引入时间步和隐状态机制，有效解决了上述问题：
 - 解决长距离依赖，通过隐状态传递历史，RNN 引入隐状态 h_t 来存储历史信息， t 时刻的隐状态由当前输入 x_t 和上一时刻的隐状态 h_{t-1} 共同决定；
 - 参数共享，无论序列有多长，RNN 在所有时间步上共享同一组权重参数，使得模型参数量不再随句子长度增加而增加，大大提高了参数效率，且具备了处理变长序列的能力；
 - 词向量的语义泛化，解决稀疏性，词向量将词映射到低维度稠密空间，使得语义相似的词在空间中距离相似，这使得模型具有很强的泛化能力，即使某个具体的词序列未在训练集中出现过，只要词义相似，RNN 依然能根据学到的语法模型预测出合理的后续词。

简述第一、二、三、四、五范式特点和应用场景

- 第一范式：概率统计时代，特点是特征工程浅层算法，依赖专家知识进行繁琐的特征工程，将非结构化数据转化为特征向量，再输入到逻辑回归等统计模型中，应用场景有垃圾邮件过滤、简单的文本分类，局限性是泛化能力差，极其依赖人工经验，特征提取耗时耗力；
- 第二范式：深度学习时代，特点是自动获取特征端到端分类，利用卷积神经网络或循环神经网络，自动从数据中学习表征表示，实现端到端的映射，减少了对人工特征的依赖，应用场景有机器翻译、图像识别、语音识别，局限性是需要海量的标注数据，模型黑盒，可解释性差，训练成本高；
- 第三范式：预训练 + 微调，特点是大量预训练数据 + 少量任务数据，以 BERT 为代表，先在海量无标注数据上进行自监督预训练，再使用少量特定任务的标注数据进行微调，以适应下游任务，应用场景有情感分析、命名实体识别、阅读理解、特定领域的问答系统，局限性是每个下游任务都需要重新微调一个专门的模型，模型不通用，存储和部署成本较高；
- 第四范式：预训练 + 提示 + 预测，特点是少量或无任务数据，以 GPT-3 为代表，不再为了任务去微调模型参数，而是通过提示将下游任务转化为预训练任务的形式，实现了少样本或零样本学习，应用场景包括创意写作、多功能聊天机器人、快速原型开发、跨任务的通用理解，局限性有模型容易产生幻觉，缺乏深度的逻辑推理能力，无法主动与物理世界交互；
- 第五范式：大模型 AGI + Agent，特点是感知、规划、行动、反馈，自主地 CoT 推理使用 API 工具，且具有长期记忆和反思修正能力，应用场景包括解决繁杂的任务、自动化科研、数字员工独立开发软件。

简述传统的事件抽取任务，并给出传统的事件抽取的建模任务有哪些，具体实现步骤

事件抽取是信息抽取的一个高级子任务，实体抽取是识别文本中名词，事件抽取就是识别文本中动词及其关联网络，核心目标是将非结构化的自然语言文本转化为结构化的数据，通常是表格或知识图谱形式，明确回答人物、时间、地点、事件等问题。

建模任务：

- 触发词识别与分类
- 事件类别识别
- 按模版抽取角色

任务涉及模型：序列标注模型 + 分类模型

具体实现步骤：

1. 预处理，识别实体候选，传统的方法可采用 BiLSTM + CRF
2. 触发词检测，发现事件核心，词汇特征分类器，例如 SVM
3. 论元抽取，填充角色模版，实体-触发词配对分类

细粒度情感分析

评论：“这是一家正宗的俄式西餐，味道浓厚，环境很好”


属性情感输出

属性	情感词	情感极性
俄式西餐	正宗	正向
味道	浓厚	正向
环境	很好	正向

设计一个情感属性关联模型，解释其原理，画出模型图

模型需要同时完成两个任务：实体抽取、情感分类，将两者关联起来

Word2Vec + BiLSTM + CRF 模型




原理解释：

- 第一步：词嵌入，通过预训练好的 Word2Vec 等静态词向量，转换成一串固定的数字列表向量
- 第二步：BiLSTM 用于把每个字放在上下文去理解，生成一个包含丰富上下文信息的特征向量，捕捉语义空间的隐式关联
- 第三步：CRF 条件随机场学习标签之间的规则，即校对转移概率，确保最终输出的标签序列在逻辑上是通顺、合理的整体

检索式问答系统包含哪几个部分，作用是什么

- 问题分析模块：理解用户意图，对输入进行分词纠错关键词提取，将文本转化成向量
- 信息检索模块：缩小范围，从海量知识库中筛选与用户问题相关的一组候选问题答案
- 答案匹配模块：通过计算语义相似度，对候选答案进行打分排序，择优选出最佳结果

特点：问题领域开放，基于非结构化Web数据；检索内容为简短的词或词组



1.问题分析

- 检测问题类型、答案类型、关注点、关系等
- 将问题改写为查询，输入搜索引擎

2.文档与段落检索

- 检索相关文档
- 相关文档划分为片段，对片段进行排序

3.答案抽取

- 在相关片段中抽取备选答案
- 对备选答案进行排序

设计一个检索式问答系统，并解释其原理

RAG：

- 预处理：将知识库中标准问题和用户输入的问题，都进行分词和去除无意义词语处理
- 语义嵌入：使用深度学习模型，如 BERT 将用户问题转化为数学向量
- 相似度计算：计算用户问题向量与库中所有问题向量之间的距离
- 排序输出：按照相似度得分，从高到低排序，输出最优的答案

Prompt 适合什么语言模型

- 自回归模型

- 掩码语言模型
- 序列到序列模型

自回归、Mask、Seq2Seq