高级人工智能

沈华伟
中国科学院计算技术研究所
2024.1.11

课程总体结构

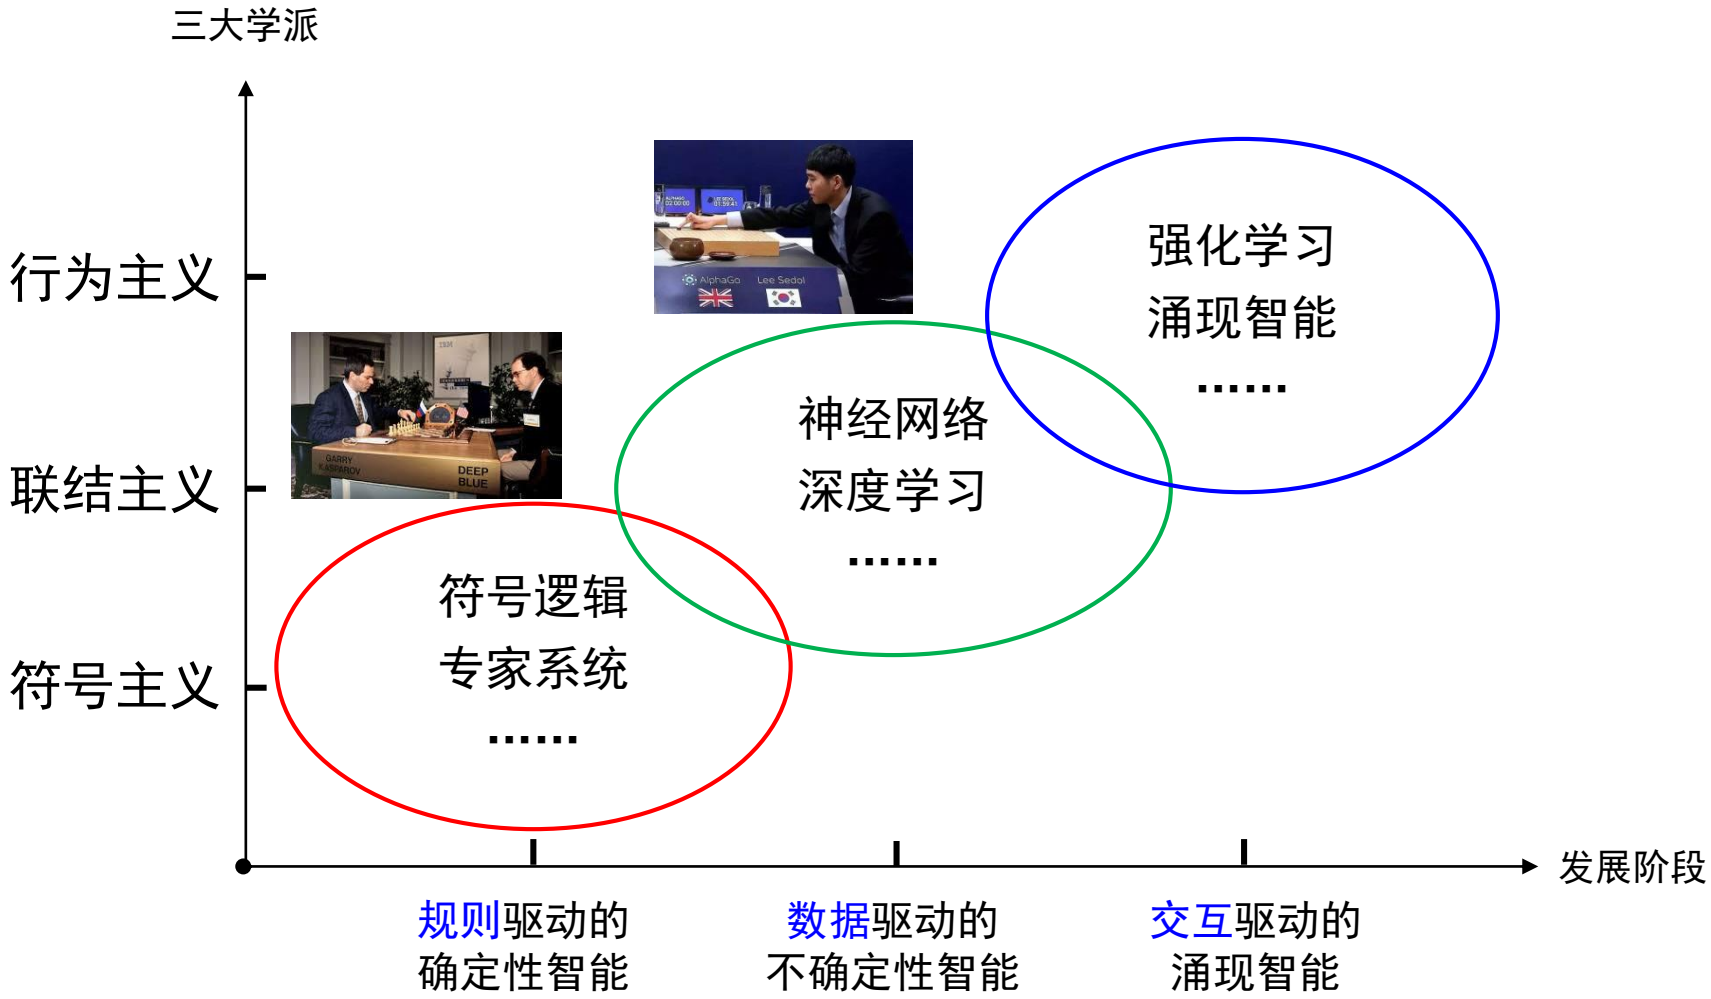
三大学派
行为主义
联结主义
符号主义
强化学习
涌现智能
.....
神经网络
深度学习
.....
符号逻辑
专家系统
.....
发展阶段
规则驱动的
确定性智能
数据驱动的
不确定性智能
交互驱动的
涌现智能

图灵测试

	类人 (Humanly)	理性 (Rationally)
思考 (Think)	像人一样思考	理性思考
行动 (Act)	像人一样行动	理性行动

图灵测试

- 图灵问题
  - ***Can Machine Think?***

A. M. Turing, *Computing Machinery and Intelligence*, Mind, 59:433-460, 1950.

阿兰·图灵
(1912-1954)
现代计算机之父

- 模仿游戏

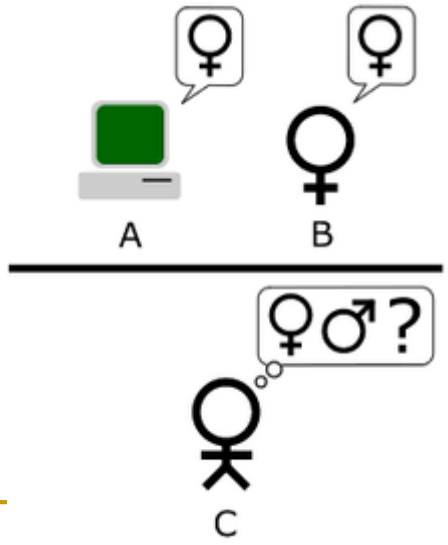

图灵测试（Turing Testing）

一个人（C）在完全不接触对方（A和B）的情况下，和对方进行一系列的问答，如果在相当长时间内，他无法根据这些问题判断对方是人（B）还是计算机（A），那么，就认为该计算机具有同人相当的智能，（即计算机是能思维的）

图灵预言：到2000年，机器可以做到5分钟内以30%的可能性让普通人分辨不出其是机器还是人

集群智能

- 代表性方法
  - 蚁群优化算法
  - 粒子群优化算法

蚁群优化算法

- **ACO: Ant Colony Optimization**
  - 一种解空间搜索方法
  - 适用于在图上寻找最优路径

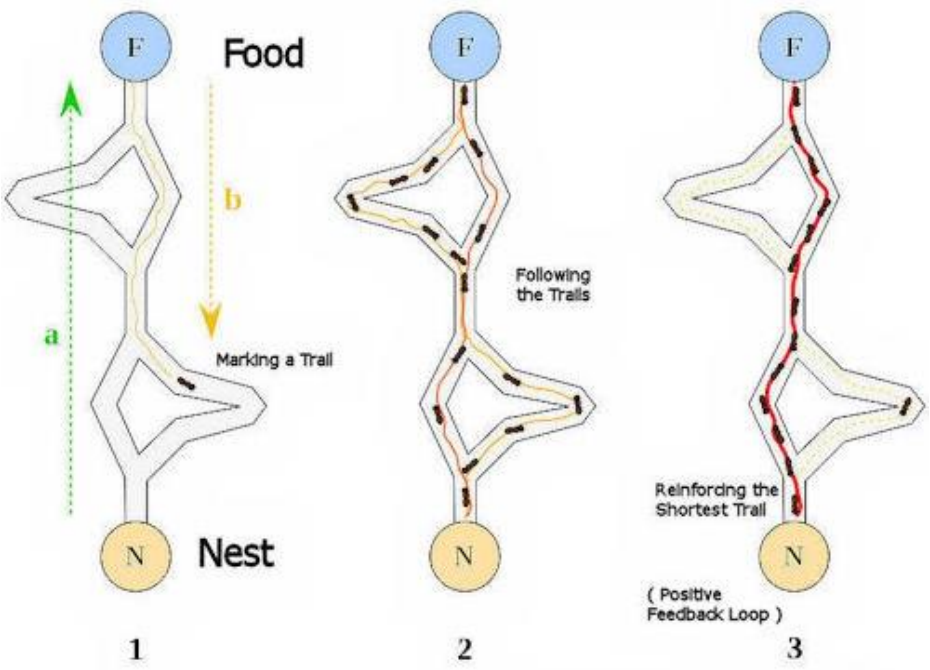

A. Colorni, M. Dorigo et V. Maniezzo, Distributed Optimization by Ant Colonies, actes de la première conférence européenne sur la vie artificielle, Paris, France, Elsevier Publishing, 134-142, 1991.

蚁群优化算法

- 形式化
  - 每个蚂蚁对应一个计算智能体
  - 蚂蚁依概率选择候选位置进行移动
  - 在经过的路径上留下“信息素”（Pheromone）
  - “信息素”随时间挥发
  - “信息素”浓度大的路径在后续的选择中会以更高的概率被选取

旅行商问题的蚁群优化求解

- 旅行商问题（TSP: Traveling Salesman Problem）
  - n个城市的有向图$G = (V, E)$

$$V = \{1,2,\cdots,n\} \qquad \mathrm{E} = \{(i,j)|i,j \in V\}$$

  - 城市之间的距离表示为

d_{ij} 为节点i和j之间的距离

  - 目标函数

$$f(w) = \sum_{l=1}^{n} d_{i_l i_{l+1}}$$

$w = (i_1, i_2, \cdots, i_n)$ 为TSP问题的任意可行解，其中 $i_{n+1} = i_1$

旅行商问题的蚁群优化求解

首先将m只蚂蚁随机放置在n个城市，位于城市i的第k只蚂蚁选择下一个城市j的概率为:

$$p_{ij}^{k}(t)=\begin{cases}\dfrac{\left(\tau_{ij}(t)\right)^{\alpha}\left(\eta_{ij}(t)\right)^{\beta}}{\sum_{k\in allowed}\left(\tau_{ik}(t)\right)^{\alpha}\left(\eta_{ik}(t)\right)^{\beta}} & j\in allowed\\ 0, & otherwise\end{cases} \qquad (1)$$

$\tau_{i,j}(t)$ 表示边(i,j)上的信息素浓度

$\eta_{i,j}(t)=1/d_{ij}$ 是根据距离定义的启发信息

α和β反映了信息素与启发信息的相对重要性

旅行商问题的蚁群优化求解

当所有蚂蚁完成周游后，按以下公式进行信息素更新

$$\Delta\tau_{ij}^{k} = f(x) = \begin{cases} \dfrac{Q}{L_k}, & (i,j) \in w_k \\ 0, & otherwise \end{cases} \tag{2}$$

$$\tau_{ij}(t+1) = \rho \cdot \tau_{ij}(t+1) + \Delta\tau_{ij}$$

$$\Delta\tau_{ij} = \sum_{k=1}^{m} \Delta\tau_{ij}^{k}$$

其中：Q为常数, w_k表示第k只蚂蚁在本轮迭代中走过的路径，L_k为路径长度，ρ为小于1的常数，反映信息素挥发速度

旅行商问题的蚁群优化求解

TSP问题蚁群算法流程

⑴初始化　随机放置蚂蚁，
⑵迭代过程

```
k=1
while k=<ItCount do (执行迭代)
     for i = 1 to m do  (对m只蚂蚁循环)
       for j = 1 to n - 1 do  (对n个城市循环)
          根据式(1)，采用轮盘赌方法在窗口外选择下一个城市j;
       将j置入禁忌表,蚂蚁转移到j;
     end for
  end for
  计算每只蚂蚁的路径长度;
  根据式(2)更新所有蚂蚁路径上的信息量;
  k = k + 1;
end while
```

⑶输出结果,结束算法.

旅行商问题的蚁群优化求解

- 蚁群大小
  - 一般情况下，蚁群中的蚂蚁个数不超过TSP图中节点的个数
- 终止条件
  - 设定迭代轮数
  - 设定最优解连续保持不变的迭代轮数

集群智能

- 代表性方法
  - 蚁群优化算法
  - 粒子群优化算法

粒子群优化算法

- **PSO: Particle Swarm Optimization**
  - 一种随机优化方法
  - 通过粒子群在解空间中进行搜索，寻找最优解（适应度最大的解）

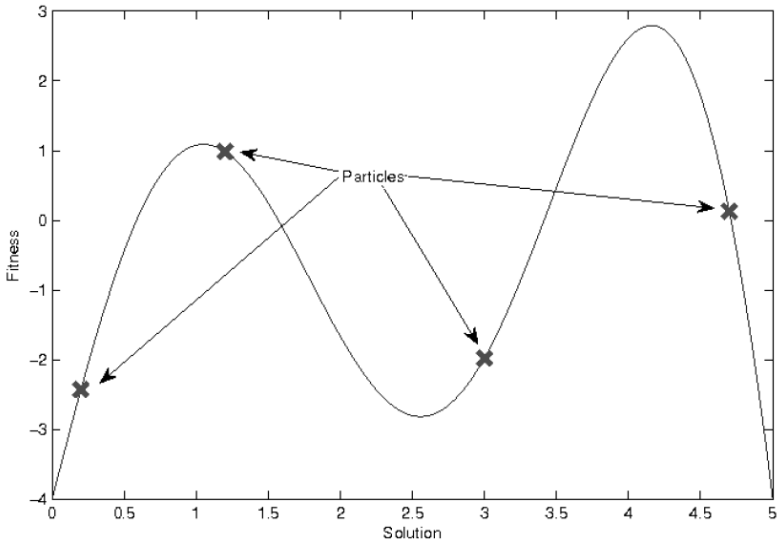

James Kennedy and Russell Eberhart. Particle swarm optimization. Proceedings of the IEEE International Conference on Neural Networks, pp. 1942–1948, Piscataway, NJ, 1995.

粒子群优化算法

- 构成要素
  - 粒子群
    - 每个粒子对应所求解问题的一个可行解
    - 粒子通过其位置和速度表示
      - 粒子i在第n轮的位置：$x_n^{(i)}$
      - 粒子i在第n轮的速度： $v_n^{(i)}$
  - 记录
    - $p_{best}^{(i)}$：粒子i的历史最好位置
    - g_{best}：全局历史最好位置
  - 计算适应度的函数
    - 适应度：$f(x)$

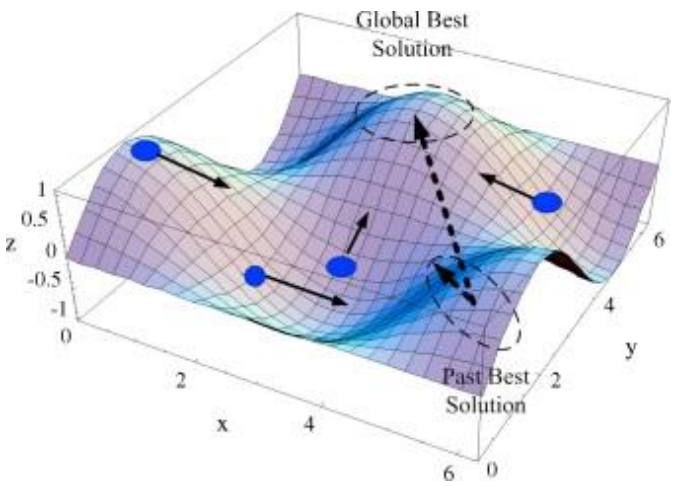

粒子群优化算法

- 算法过程描述
  - 初始化
    - 初始化粒子群：每个粒子的位置和速度，即$x_0^{(i)}$和$v_0^{(i)}$
    - $p_{best}^{(i)}$和g_{best}
  - 循环执行如下三步直至满足结束条件
    - 计算每个粒子的适应度：$f\left(x_n^{(i)}\right)$
    - 更新每个粒子历史最好适应度及其相应的位置，更新当前全局最好适应度及其相应的位置
    - 更新每个粒子的速度和位置

$$v_{n+1}^{(i)} = v_n^{(i)} + c_1 * r_1 * \left(p_{best}^{(i)} - x_n^{(i)}\right) + c_2 * r_2 * \left(g_{best} - x_n^{(i)}\right)$$

$$x_{n+1}^{(i)} = x_n^{(i)} + v_{n+1}^{(i)}$$

粒子群优化算法

- 粒子速度更新公式解读

$$v_{n+1}^{(i)} = \boxed{v_n^{(i)}} + c_1 * r_1 * \boxed{\left(p_{best}^{(i)} - x_n^{(i)}\right)} + c_2 * r_2 * \boxed{\left(g_{best} - x_n^{(i)}\right)}$$

①惯性项

保持原速度不变的倾向

②记忆项

回到历史最好位置的倾向

③社会项

走向粒子群全局最好位置的倾向

粒子群优化算法

- 算法终止条件
  - 迭代的轮数
  - 最佳位置连续未更新的轮数
  - 适应度函数的值到达预期要求

大纲

- 强化学习
- 多臂赌博机
- 马尔科夫决策过程

多臂赌博机 (Multi-armed bandit)

- 一台赌博机有多个摇臂，每个摇臂摇出的奖励（reward）大小不确定，玩家希望摇固定次数的臂所获得的期望累积奖励最大

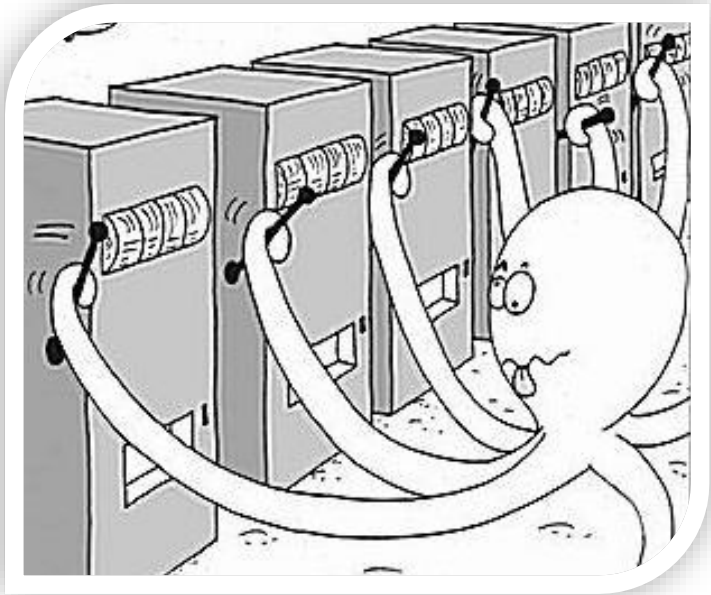

问题形式化

- 行为：摇哪个臂
- 奖励：每次摇臂获得的奖金
- A_t表示第t轮的行为，R_t表示第t轮获得的奖励
- 第t轮采取行为a的期望奖励为：

$$q_*(a) \doteq \mathbb{E}[R_t | A_t = a]$$

Question:

假如摇臂T次，那么按照什么策略摇臂，才能使期望累积奖励最大呢？

Answer:

当$q_*(a)$已知时，每次都选择$q_*(a)$最大的a（贪心策略）

贪心策略

- 一般情况下， $q_*(a)$ 对于玩家而言是未知的或具有不确定性，此时该采用什么样的策略呢？
- 玩家在第t轮时只能依赖于当时对$q_*(a)$的估值$Q_t(a)$进行选择
- 此时，贪心策略在第t轮选择$Q_t(a)$最大的a

在$q_*(a)$未知时，贪心策略还是最好的策略吗？

利用和探索

- 利用：Exploitation
  - 按照贪心策略进行选择，即选择$Q_t(a)$最大的行为a
  - 优点：最大化即时奖励
  - 缺点：由于$Q_t(a)$只是对$q_*(a)$的估计，估计的不确定性导致按照贪心策略选择的行为不一定是$q_*(a)$最大的行为

- 探索：Exploration
  - 选择贪心策略之外的行为（non-greedy actions）
  - 缺点：短期奖励会比较低
  - 优点：长期奖励会比较高，通过探索可以找出奖励更大的行为，供后续选择

✓ 每步选择在“利用”和“探索”中二选一

✓ 如何平衡“利用” 和“探索” 是关键

贪心策略和ε贪心策略

- 贪心策略形式化地表示为

$$A_t \doteq \arg\max_a Q_t(a)$$

当有多个行为的$Q_t(a)$同时为最大时，随机选择一个

- $\boldsymbol{\varepsilon}$贪心策略
  - 以概率$1-\boldsymbol{\varepsilon}$按照贪心策略进行行为选择——Exploitation
  - 以概率$\boldsymbol{\varepsilon}$在所有行为中随机选择一个——Exploration
  - $\boldsymbol{\varepsilon}$的取值取决于$q_*(a)$的方差，方差越大$\boldsymbol{\varepsilon}$取值应越大

行为选择策略

- 如何制定合适的行为选择策略？
  - 贪心策略：选择当前估值最好的行为
  - ε贪心策略：以一定的概率随机选择非贪心行为（non-greedy actions），但是对于非贪心行为不加区分

- 行为选择策略
  - 平衡exploitation和exploration，应对行为估值的不确定性
  - 关键：确定每个行为被选择的概率

乐观初值法

- 行为的初始估值
  - 前述贪心策略中，每个行为的初始估值为0
  - 每个行为的初始估值可以帮助我们引入先验知识
  - 初始估值还可以帮助我们平衡exploitation和exploration

- 乐观初值法：Optimistic Initial Values
  - 为每个行为赋一个高的初始估值
  - 好处：初期每个行为都有较大机会被explore

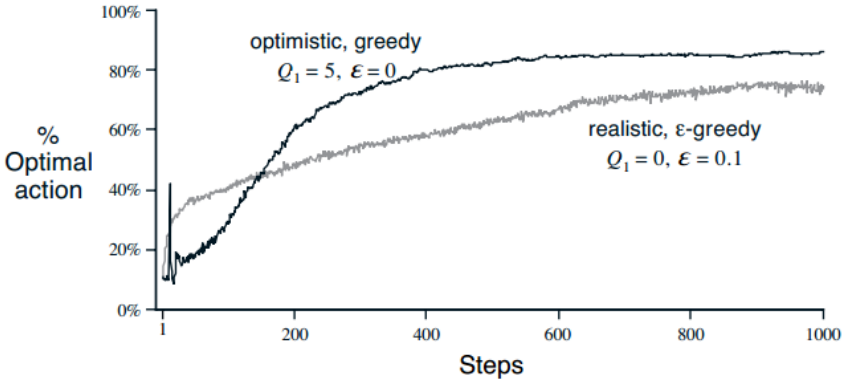

UCB行为选择策略

- UCB：Upper-Confidence-Bound

$$A_t \doteq \underset{a}{\operatorname{argmax}} \left[Q_t(a) + c\sqrt{\frac{\ln t}{N_t(a)}} \right]$$

$N_t(a)$表示时刻t之前行为a被选择的次数

公式解读

- ✓ 选择潜力大的行为：依据估值的置信上界进行行为选择
- ✓ 第一项表示当前估值要高，e.g., 接近greedy action
- ✓ 第二项表示不确定性要高，e.g., 被选择的次数少
- ✓ 参数c用来控制exploration的程度

UCB策略 vs. ε贪心策略

UCB策略一般会优于ε贪心策略，不过最初几轮相对较差

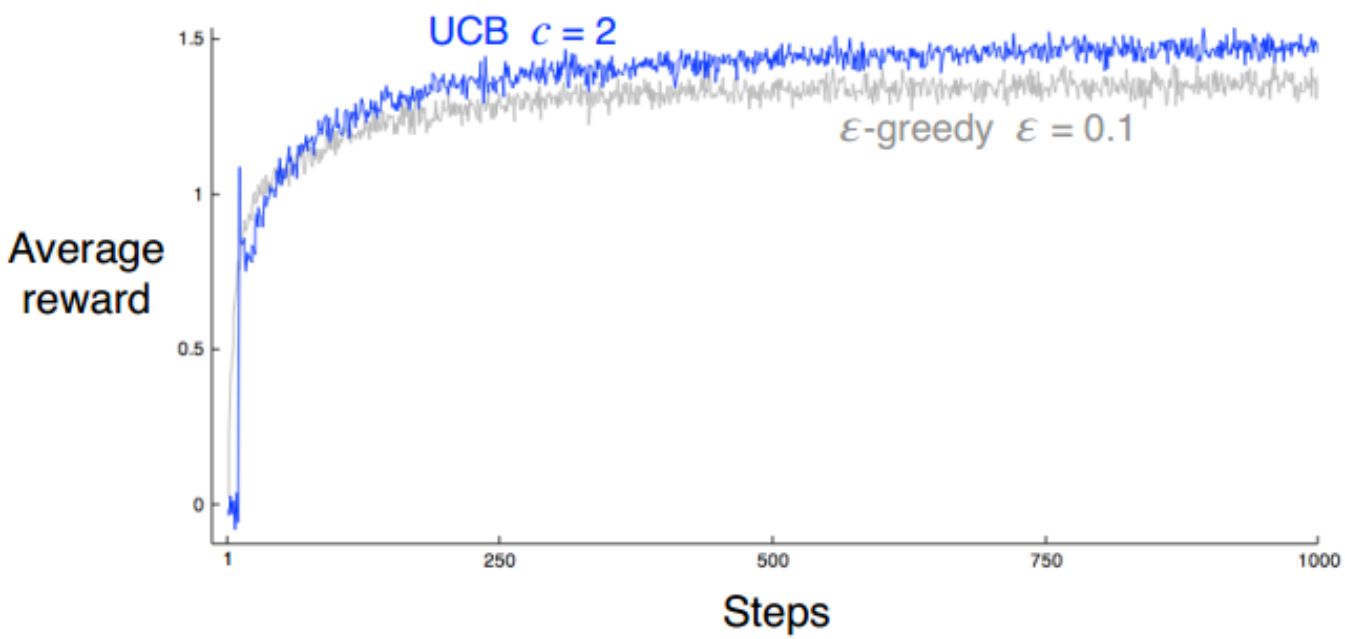

UCB策略实现起来比ε贪心策略要复杂，在多臂赌博机之外的强化学习场景中使用较少

大纲

- 强化学习
- 多臂赌博机
- 马尔科夫决策过程

马尔科夫决策过程的要素

- 智能体和环境按照离散的时间步进行交互

  $t = 0,1,2,3,\cdots$

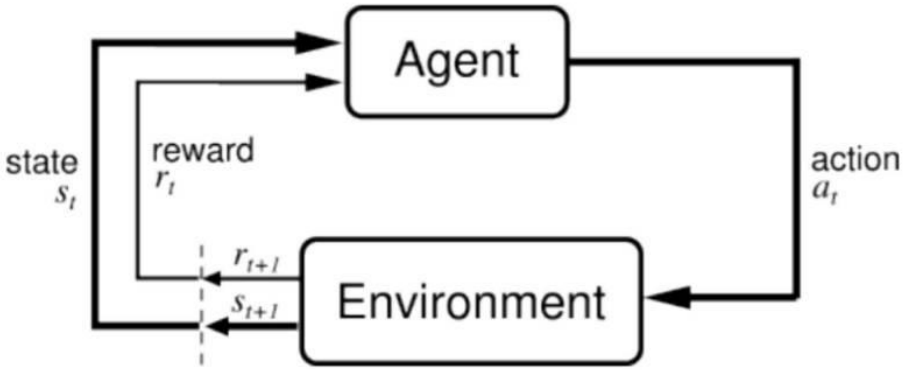

- 形式化记号
  - 智能体在时间步t所处的状态记为$S_t \in S$
  - 智能体在时间步t所采取的行为记为$A_t \in A(s)$
  - 采取行为A_t后智能体转到状态S_{t+1}，并获得奖励$R_{t+1} \in R$
  - 马尔科夫决策过程产生的序列记为

$$S_0, A_0, R_1, S_1, A_1, R_2, S_2, A_2, R_3, \ldots$$

奖励假设

- 目标和奖励
  - 目标：长期的或最终的
  - 奖励：即时的
- 奖励假设：reward hypothesis

That all of what we mean by goals and purposes can be well thought of as the maximization of the expected value of the cumulative sum of a received scalar signal (called reward)

- 如何设置奖励呢？
  - 奖励是我们与智能体进行交互的途径

策略和状态估值函数

- 策略
  - 状态到行为的映射
  - 随机式策略：$\pi(a|s)$
  - 确定式策略：$a = \pi(s)$
- 给定策略π，状态估值函数(state-value function)定义为

$$v_\pi(s) \doteq \mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,\middle|\, S_t = s\right], \text{ for all } s \in \mathcal{S}$$

- 给定策略π，行为估值函数(action-value function)定义为

$$q_\pi(s,a) \doteq \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a] = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,\middle|\, S_t = s, A_t = a\right]$$

贝尔曼方程

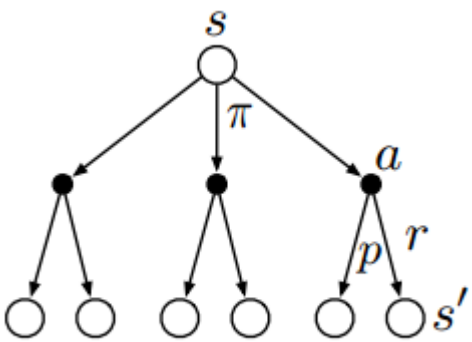

Backup diagram for v_π

- 状态估值函数的贝尔曼方程

$$
\begin{aligned}
v_\pi(s) &\doteq \mathbb{E}_\pi[G_t \mid S_t = s] \\
&= \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \\
&= \sum_a \pi(a|s) \sum_{s'} \sum_r p(s', r|s, a)\Big[r + \gamma \mathbb{E}_\pi[G_{t+1}|S_{t+1} = s']\Big] \\
&= \sum_a \pi(a|s) \sum_{s',r} p(s', r|s, a)\Big[r + \gamma v_\pi(s')\Big], \quad \text{for all } s \in \mathcal{S}
\end{aligned}
$$

Tip!

Bellman equation expresses a relationship between the value of a state and the values of its successor states

贝尔曼方程的作用

- **贝尔曼方程**定义了状态估值函数的依赖关系
  - 给定策略下，每个状态的估值视为一个变量
  - 所有状态（假如有n个）的估值根据贝尔曼方程形成了一个具有n个方程和n个变量的线性方程组
  - 求解该方程组即可得到该策略下每个状态的估值

例子：Gridworld

- 游戏规则：正常移动一次的奖励为0；出界时回到当前位置，奖励为-1；A位置选择任意方向都到达A‘，奖励为+10；B位置选择任意方向都到达B’，奖励为+5；折扣率$\gamma = 0.9$。
- 假定策略为：从每个格子等概率选择四个移动方向（行为）

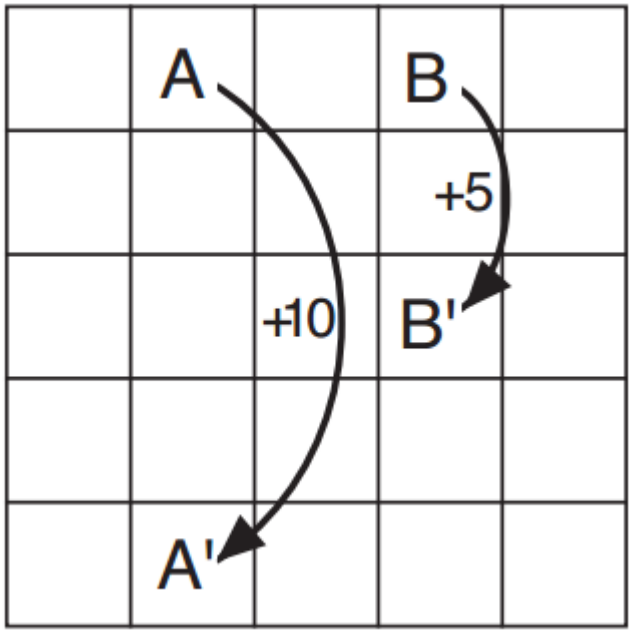

Actions

策略

3.3	8.8	4.4	5.3	1.5
1.5	3.0	2.3	1.9	0.5
0.1	0.7	0.7	0.4	-0.4
-1.0	-0.4	-0.4	-0.6	-1.2
-1.9	-1.3	-1.2	-1.4	-2.0

游戏规则

策略对应的状态估值函数

注意：这里的计算精度为小数点后一位

例子：Gridworld

- 最优状态估值函数和最优策略

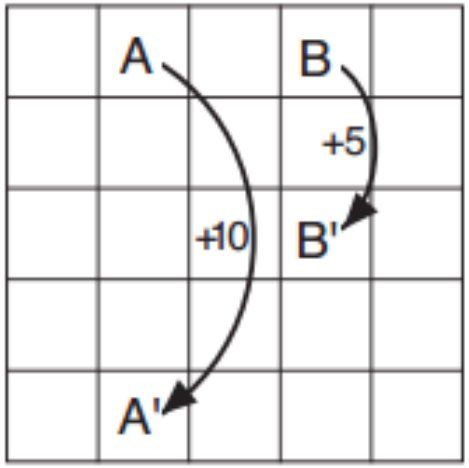

Gridworld

22.0	24.4	22.0	19.4	17.5
19.8	22.0	19.8	17.8	16.0
17.8	19.8	17.8	16.0	14.4
16.0	17.8	16.0	14.4	13.0
14.4	16.0	14.4	13.0	11.7

v_*

最优策略对应的状态估值函数

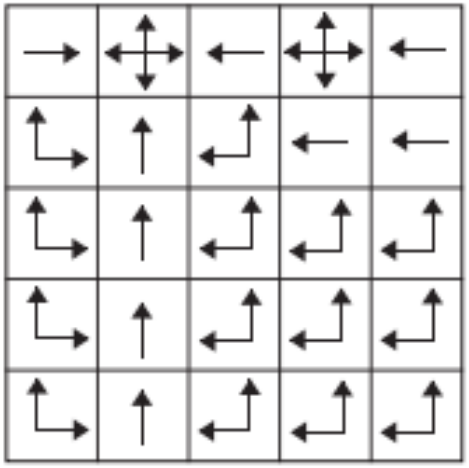

π_*

最优策略

大纲

- 策略学习
  - 动态规划方法
  - 蒙特卡洛方法
  - 时序差分方法
  - 参数近似方法

策略估值

- 给定策略π，该策略下的状态估值函数满足

$$
\begin{aligned}
v_\pi(s) &\doteq \mathbb{E}_\pi[G_t \mid S_t = s] \\
&= \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \\
&= \mathbb{E}_\pi[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s] \\
&= \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a)\Big[r + \gamma v_\pi(s')\Big]
\end{aligned}
$$

- 假如环境$p(s',r|s,a)$已知，状态估值函数的求解方式有
  - 求解线性方程组
    - 计算开销大
  - 寻找不动点——迭代策略估值

策略提升

- 策略估值的目标是为了寻找更优的策略（策略提升）
  - 策略估值根据策略π计算其估值函数v_π

- 策略提升
  - 根据当前策略的估值函数，寻找更优的策略（如果存在），逐步寻找到最优策略
    - 根据策略π的估值函数v寻找更优策略π'
  - 提升方法
    - 给定一个确定策略π，在状态s下选择行为a，后续按照策略π行动所得的估值$q_\pi(s,a)$是否高于完全按照策略π行动得到的估值$v_\pi(s)$

$$
\begin{aligned}
q_\pi(s,a) &\doteq \mathbb{E}[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s, A_t = a] \\
&= \sum_{s',r} p(s',r|s,a)\Big[r + \gamma v_\pi(s')\Big]
\end{aligned}
$$

策略迭代

- 从初始策略π_0开始，迭代进行“策略估值(E)”和“策略提升(I)”，最终得到最优策略π_*

$$\pi_0 \xrightarrow{\text{E}} v_{\pi_0} \xrightarrow{\text{I}} \pi_1 \xrightarrow{\text{E}} v_{\pi_1} \xrightarrow{\text{I}} \pi_2 \xrightarrow{\text{E}} \cdots \xrightarrow{\text{I}} \pi_* \xrightarrow{\text{E}} v_*$$

Policy iteration (using iterative policy evaluation)

1. Initialization
   $V(s) \in \mathbb{R}$ and $\pi(s) \in \mathcal{A}(s)$ arbitrarily for all $s \in \mathcal{S}$

2. Policy Evaluation
   Repeat
   $\quad\Delta \leftarrow 0$
   $\quad$For each $s \in \mathcal{S}$:
   $\quad\quad v \leftarrow V(s)$
   $\quad\quad V(s) \leftarrow \sum_{s',r} p(s',r|s,\pi(s))\big[r + \gamma V(s')\big]$
   $\quad\quad \Delta \leftarrow \max(\Delta, |v - V(s)|)$
   until $\Delta < \theta$ (a small positive number)

3. Policy Improvement
   policy-stable $\leftarrow$ *true*
   For each $s \in \mathcal{S}$:
   $\quad$*old-action* $\leftarrow \pi(s)$
   $\quad\pi(s) \leftarrow \arg\max_a \sum_{s',r} p(s',r|s,a)\big[r + \gamma V(s')\big]$
   $\quad$If *old-action* $\neq \pi(s)$, then *policy-stable* $\leftarrow$ *false*
   If *policy-stable*, then stop and return $V \approx v_*$ and $\pi \approx \pi_*$; else go to 2

估值迭代

- 从初始状态估值v_0开始，进行估值迭代，找到最优状态估值v_*，进而根据v_*按照贪心方式得到最优策略π_*

Value iteration

Initialize array V arbitrarily (e.g., $V(s) = 0$ for all $s \in \mathcal{S}^+$)

Repeat
  $\Delta \leftarrow 0$
  For each $s \in \mathcal{S}$:
    $v \leftarrow V(s)$
    $V(s) \leftarrow \max_a \sum_{s',r} p(s', r \mid s, a)\big[r + \gamma V(s')\big]$
    $\Delta \leftarrow \max(\Delta, |v - V(s)|)$
until $\Delta < \theta$ (a small positive number)

Output a deterministic policy, $\pi \approx \pi_*$, such that
  $\pi(s) = \arg\max_a \sum_{s',r} p(s', r \mid s, a)\big[r + \gamma V(s')\big]$

广义策略迭代

- 迭代进行两个阶段：
  - 策略估值：让新的估值和当前的策略保持一致
  - 策略提升：根据当前估值，得到相应的贪心策略

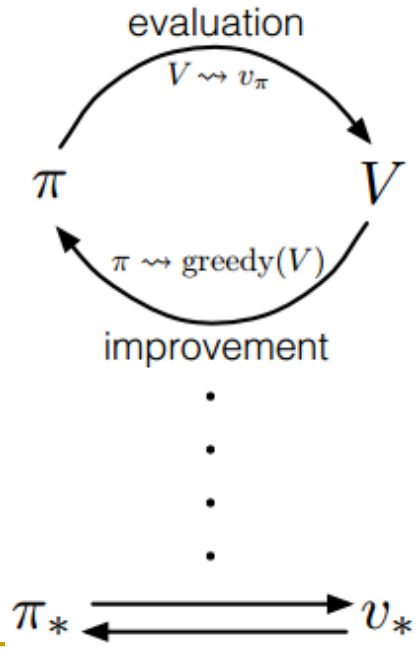

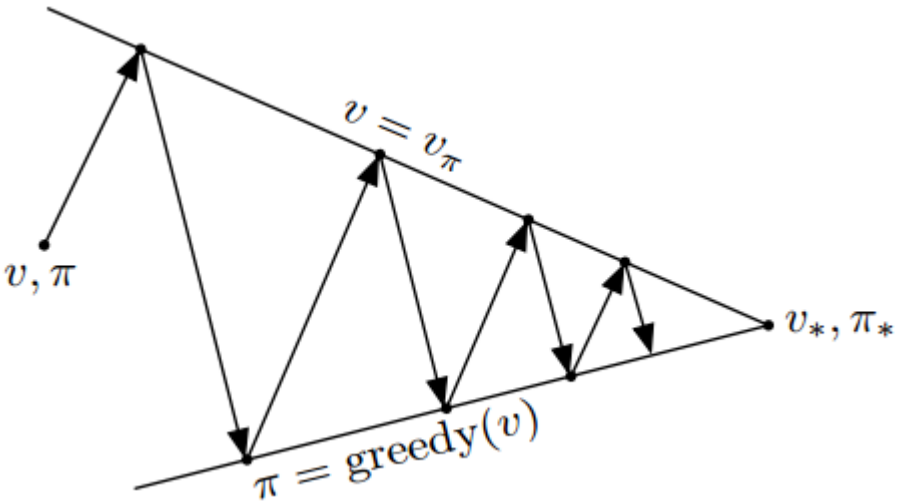

大纲

- 策略学习
  - 动态规划方法
  - 蒙特卡洛方法
  - 时序差分方法
  - 参数近似方法

蒙特卡洛方法的动机

- 动态规划方法需要知道关于环境的完整模型
- 大部分情况下没有关于环境的完整模型，或模型过于复杂
- 蒙特卡洛方法
  - 从真实或者模拟的经验(experience)中计算状态（行动）估值函数
  - 不需要关于环境的完整模型

蒙特卡洛方法

- 状态估值
  - 从某个状态s出发，使用当前策略π通过蒙特卡洛模拟的方式生成多个episode，使用这些episode的平均收益（return）近似状态估值函数$v_\pi(s)$

First-visit MC prediction, for estimating $V \approx v_\pi$

Initialize:
  $\pi \leftarrow$ policy to be evaluated
  $V \leftarrow$ an arbitrary state-value function
  $Returns(s) \leftarrow$ an empty list, for all $s \in \mathcal{S}$

Repeat forever:
  Generate an episode using π
  For each state s appearing in the episode:
    $G \leftarrow$ the return that follows the first occurrence of s
    Append G to $Returns(s)$
    $V(s) \leftarrow \text{average}(Returns(s))$

收敛速度大约为：$1/\sqrt{n}$（n表示蒙特卡洛模拟次数）

蒙特卡洛方法的优势

- 直接根据真实经验或模拟经验计算状态估值函数
- 不同状态的估值在计算时是独立的
  - 不依赖于“自举”方法

基于蒙特卡洛方法的策略迭代

- 在完整的环境模型未知时，仅有状态估值$v_\pi(s)$无法得出策略π

- 大多数情况下，直接使用蒙特卡洛方法计算行为估值函数$q_\pi(s,a)$，进而采用贪心方法得到策略π

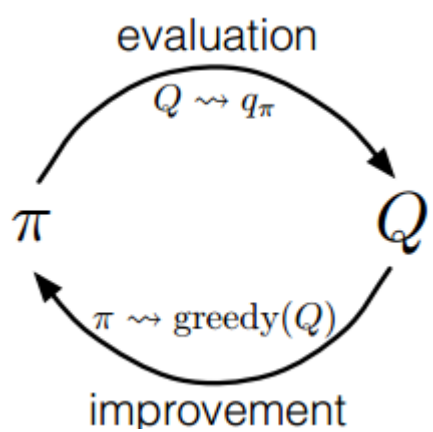

$$\pi_0 \xrightarrow{\text{E}} q_{\pi_0} \xrightarrow{\text{I}} \pi_1 \xrightarrow{\text{E}} q_{\pi_1} \xrightarrow{\text{I}} \pi_2 \xrightarrow{\text{E}} \cdots \xrightarrow{\text{I}} \pi_* \xrightarrow{\text{E}} q_*$$

$$\pi(s) \doteq \arg\max_a q(s,a)$$

大纲

- 策略学习
  - 动态规划方法
  - 蒙特卡洛方法
  - 时序差分方法
  - 参数近似方法

时序差分方法

- 非平稳情形下的蒙特卡洛方法（恒定步长）

$$V(S_t) \leftarrow V(S_t) + \alpha\left[G_t - V(S_t)\right]$$

G_t表示第t轮蒙特卡洛模拟的收益
$V(S_t)$表示第t轮对状态S_t的估值

- 时序差分方法（Temporal Difference: TD）

$$V(S_t) \leftarrow V(S_t) + \alpha\left[R_{t+1} + \gamma V(S_{t+1}) - V(S_t)\right]$$

不需要根据完整的episode计算G_t，只需要模拟几步（这里是1步）之后更新状态估值

时序差分方法分析

- 时序差分方法是强化学习中最核心的策略学习方法
- TD和蒙特卡洛方法的联系和区别
  - 联系：都是从经验中学习
    - 非平稳情形下的蒙特卡洛方法是TD的特例
  - 区别：蒙特卡洛方法需要episode完整的信息，TD只需要episode的部分信息
- TD和动态规划方法的联系和区别
  - 联系：TD和动态规划方法都采用自举的方法
  - 区别：动态规划方法依赖于完整的环境模型进行估计，TD依赖于经验进行估计

时序差分方法分析

- 时序差分方法是“learn a guess from a guess”
- 时序差分方法收敛吗？
  - 收敛
- 时序差分方法和蒙特卡洛方法收敛速度哪个快？

动态规划/蒙特卡洛/时序差分对比

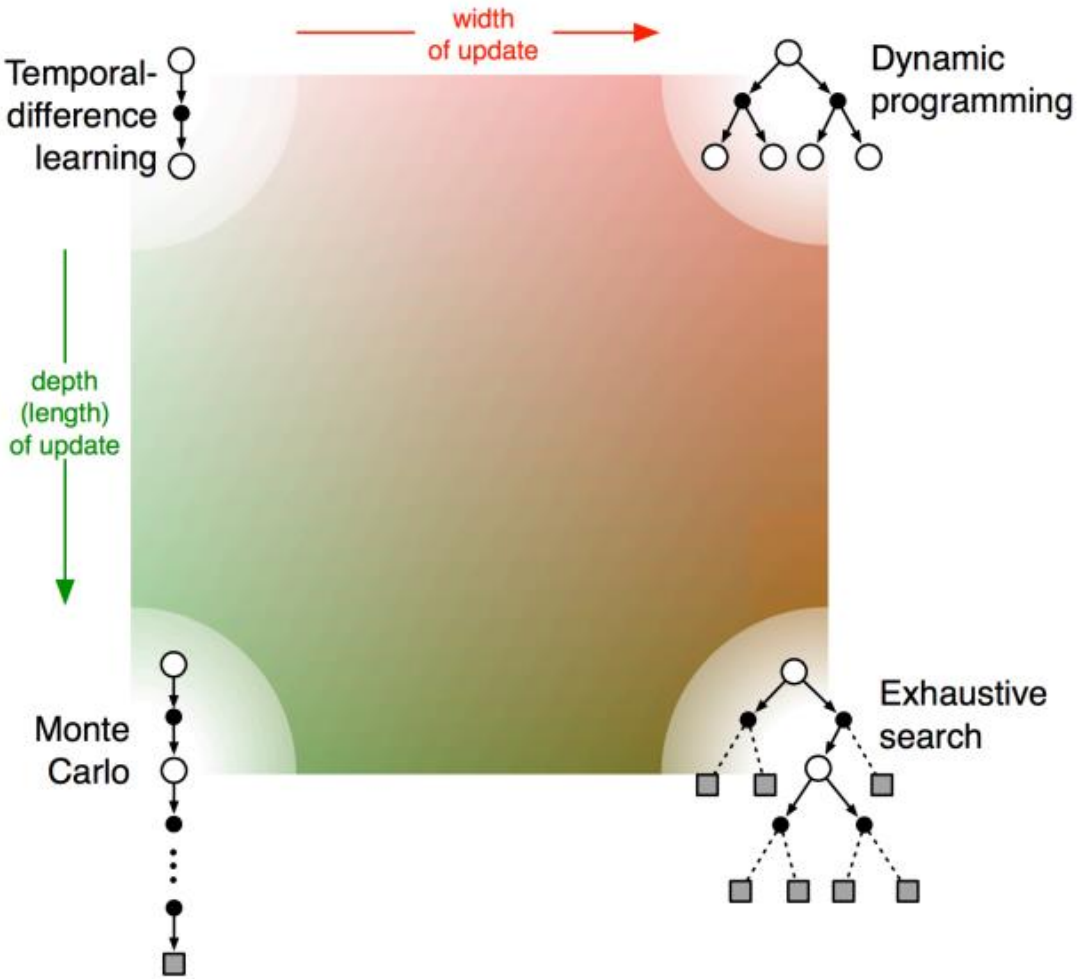

课程内容

- 博弈
  - 基本概念
  - 纳什均衡
  - 机制设计
- 两个经济学的应用
  - 拍卖
  - 讨价

博弈的要素

- 局中人（Player）
  - 在博弈中有权决定自己行动方案的博弈参加者
  - 局中人不一定是具体的人
    - 如球队、军队、企业
  - 博弈中利益完全一致的参与者只能看成一个局中人
    - 如桥牌中的南北方和东西方
- 重要假设：局中人是自私的理性人
  - 不存在侥幸心理
  - 不可能利用其它局中人的失误来扩大自己的利益
  - 以最大化个人利益为目的

博弈的要素

- 策略集合(Strategy Set)
  - 策略：博弈中可供局中人选择的行动方案
  - 参加博弈的局中人i的策略集合记为A_i
  - 所有局中人的策略形成的策略组，称为局势，记作S
  - 多人博弈中假定有 n个局中人，每个局中人从自己的策略集合中选择一个策略s_i， $s_i \in A_i$ ，这样就形成了一个局势$S = \{s_1, s_1, \cdots, s_n\}$

- 田忌赛马中田忌的策略集合
  - {上中下、上下中、中上下、中下上、下上中、下中上}

博弈的要素

- 效用函数(Payoff)
  - 通常用U来表示
  - 对每个参与博弈的局中人，都有一个相应的效用函数
  - 效用函数在静态博弈中一般是局势的函数
  - 在动态博弈中效用函数可能是局势的函数，也可能还有其它因素，比如时间
  - 每个局中人的目的都是最大化自己的效用

博弈案例

- 田忌赛马
  - （田）忌数与齐诸公子驰逐重射。孙子见其马足不甚相远，马有上、中、下辈。于是孙子谓田忌曰：“君弟重射，臣能令君胜。”田忌信然之，与王及诸公子逐射千金。及临质，孙子曰：“今以君之下驷与彼上驷，取君上驷与彼中驷，取君中驷与彼下驷。”既驰三辈毕，而田忌一不胜而再胜，卒得王千金。

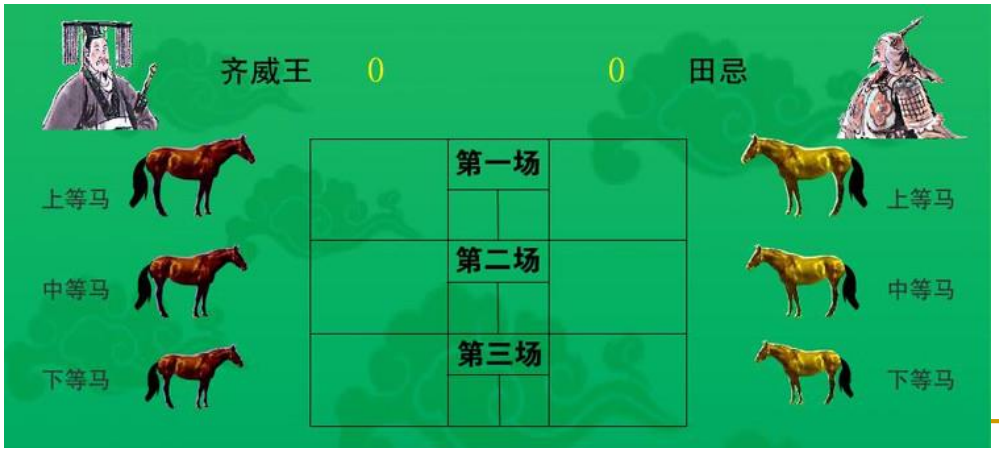

	第一场	第二场	第三场	获胜方
齐王	上	中	下	
田忌 1	上	中	下	齐王
田忌 2	上	下	中	齐王
田忌 3	中	上	下	齐王
田忌 4	中	下	上	齐王
田忌 5	下	上	中	田忌
田忌 6	下	中	上	齐王

囚徒困境

- 局中人
  - 两个囚徒
- 策略
  - 抗拒
  - 坦白
- 效用函数矩阵

囚徒B

囚徒A		抗拒	坦白
	抗拒	-1,-1	-10,0
	坦白	0,-10	-3,-3

剪刀–石头–布(Rock-paper-scissors)

- 局中人
  - 两个玩家
- 策略
  - 剪刀、石头、布
- 效用函数矩阵

玩家二

玩家一	剪刀	石头	布
剪刀	0,0	-1,1	1,-1
石头	1,-1	0,0	-1,1
布	-1,1	1,-1	0,0

纳什均衡

- 最佳应对
  - 假设s是局中人1的一个选择策略， t是局中人2的一个选择策略； $U_1(s,t)$ 是局中人1从这组决策中获得的收益，$U_2(s,t)$ 是局中人2从这组决策中获得的收益
  - 针对局中人2的策略t，若局中人1用策略s产生的收益大于或等于其任何其他策略，则称策略s是局中人1对局中人2的策略t的最佳应对
    - $U_1(s,t) \geq U_1(s',t)$，s'是局中人1除s外的其它策略
  - 如果一个局中人的某个策略对其它局中人的任何策略都是最佳应对，那么这个策略就是该局中人的占优策略

纳什均衡

- 纳什均衡
  - 定义：如果一个局势下，每个局中人的策略都是相对其他局中人当前策略的最佳应对，则称该局势是一个纳什均衡
- 纳什均衡就是博弈的一个均衡解
- 是一个僵局
  - 即给定其他人不动，没有人有动的积极性
  - 谁动谁吃亏

纳什均衡

- 例子：囚徒困境
  - 纳什均衡：双方都坦白
    - 一方保持策略不变（坦白），另一方如果改变策略（抗拒），其效用会降低（从-3变成-10）

囚徒B

囚徒A		抗拒	坦白
	抗拒	-1,-1	-10,0
	坦白	0,-10	-3,-3

混合策略纳什均衡

- 例子：剪刀-石头-布
  - 玩家一的策略选择分布记为$p = \{p_1, p_2, 1 - p_1 - p_2\}$，玩家二的策略选择分布记为$q = \{q_1, q_2, 1 - q_1 - q_2\}$
  - 假设玩家一的策略分布不变，玩家二策略选择的效用为
    - 剪刀：$0 * p_1 + (-1) * p_2 + 1 * (1 - p_1 - p_2) = 1 - p_1 - 2p_2$
    - 石头：$1 * p_1 + 0 * p_2 + (-1) * (1 - p_1 - p_2) = 2p_1 + p_2 - 1$
    - 布：$(-1) * p_1 + 1 * p_2 + 0 * (1 - p_1 - p_2) = p_2 - p_1$
  - 令玩家二的各个策略的效用相等，得到$p_1 = p_2 = \frac{1}{3}$
  - 同理可得$q_1 = q_2 = \frac{1}{3}$
- 剪刀-石头-布的混合纳什均衡态
  - 每个玩家各以1/3的概率选择剪刀、石头和布
  - 期望收益为0

玩家二

玩家一	剪刀	石头	布
剪刀	0,0	-1,1	1,-1
石头	1,-1	0,0	-1,1
布	-1,1	1,-1	0,0

社会最优

- 帕累托最优
  - 以意大利经济学家维尔弗雷多·帕累托的名字命名
  - 对于一组策略选择（局势），若不存在其他策略选择使所有参与者得到至少和目前一样高的回报，且至少一个参与者会得到严格较高的回报，则这组策略选择为帕累托最优
- 社会最优
  - 使参与者的回报之和最大的策略选择（局势）
  - 社会最优的结果一定也是帕累托最优的结果
  - 帕累托最优不一定是社会最优

社会最优示例

- 囚徒困境案例

囚徒B

囚徒A		抗拒	坦白
	抗拒	-1,-1	-10,0
	坦白	0,-10	-3,-3

帕累托最优的决策组合一共有3个，分别是（坦白，抗拒），（抗拒，坦白）和（抗拒，抗拒），纳什均衡策略组合（坦白，坦白）不是帕累托最优，社会最优策略组合是（抗拒，抗拒）

课程内容

- 博弈
  - 基本概念
  - 纳什均衡
  - 机制设计
- 应用案例
  - 拍卖
  - 讨价

首价密封报价拍卖

- 纳什均衡
  - 每个竞拍者的报价低于其对商品的估价
- 解读
  - 共有n个竞拍者，竞拍者i的估价记为v_i，报价记为b_i，其他竞拍者的估价服从$[a,b]$区间上的均匀分布，且诚实出价
  - $b_i < a$时，竞标失败，收益为0
  - 竞拍者i赢得竞拍的概率为 $\left(\frac{b_i - a}{b - a}\right)^{n-1}$
  - 竞拍者的期望收益是 $f(b_i) = (v_i - b_i)\left(\frac{b_i - a}{b - a}\right)^{n-1}$

首价密封报价拍卖

- 解读（续）
  - 期望收益

$$f(b_i) = (v_i - b_i)\left(\frac{b_i - a}{b - a}\right)^{n-1}$$

  - 期望收益关于报价b_i的梯度为

$$f'(b_i) = -\left(\frac{b_i - a}{b - a}\right)^{n-1} + (n-1)(v_i - b_i)\left(\frac{b_i - a}{b - a}\right)^{n-2}\frac{1}{b - a}$$

$$= \left(\frac{b_i - a}{b - a}\right)^{n-2}\left(\frac{-nb_i + a + (n-1)v_i}{b - a}\right)$$

  - 最优报价为

$$b_i^* = \frac{a + (n-1)v_i}{n}$$

✓ 最优报价低于估价
✓ 竞拍者越多，报价越接近于估价

次价密封报价拍卖

- 纳什均衡
  - 每个竞拍者会倾向于采用其对商品的估价进行报价

- 解读
  - 给定一个竞拍者，其估价记为v，报价记为b，其他竞拍者的最高报价记为b^*
  - 理性行为假设下，报价不会高于估价，即$b \leq v$
  - 此时，根据b^*的取值有三种情形
    - $b^* > v$：收益为0；将报价从b提高到v，收益不变
    - $b^* < b$：收益为$v - b^*$；将报价从b提高到v，收益不变
    - $b \leq b^* \leq v$：收益为0；将报价从b提高到v，收益变为$v - b^*$

课程内容

- 博弈
  - 基本概念
  - 纳什均衡
  - 机制设计
- 应用案例
  - 拍卖
  - 讨价

讨价

- 卖家和买家之间的博弈
- 讨价的对象是双方对商品估价之差
  - 假设所有因素都体现在估价中
    - 时间、情感、眼缘等
  - 例子：
    - 衣服进价80，标价200
    - 卖家对衣服的估价在80和200之间，譬如120
    - 买家的估价假如为160
    - 讨价的对象是双方的估价之差，即160-120=40
- 后续的讨论中，将讨价对象视为整体1
  - 卖家的估价为0，买家的估价为1

课程内容

- **maxmin策略和minmax策略**
- 匹配市场
- 中介市场
- 议价权

maxmin策略

- maxmin策略
  - 最大化自己最坏情况时的效用（收益）

$$\arg\max_{\boxed{s_i}} \min_{\boxed{s_{-i}}} \boxed{u_i(s_i, s_{-i})}$$

局中人i的策略

除i之外其他局中人的策略

局中人i的效用函数

maxmin策略示例

- 性别大战
  - 妻子的策略：以概率p选择韩剧，以概率$1-p$选择体育
  - 丈夫的策略：以概率q选择韩剧，以概率$1-q$选择体育
- 妻子的期望收益

$$u_w(p,q) = 2pq + (1-p)(1-q) = 3pq - p - q + 1$$

- 妻子的期望收益关于丈夫的策略q是单调的
  - 最小值的可能取值点：$q = 0$或$q = 1$
- 妻子的最坏期望收益

$$\min_q u_w(p,q) = \min(1-p, 2p)$$

- 妻子的maxmin策略为

$$\arg\max_p \min_q u_w(p,q)$$

妻子

丈夫

	韩剧	体育
韩剧	1,2	0,0
体育	0,0	2,1

丈夫: h　　妻子: w

maxmin策略示例

- 性别大战

$$\arg\max_p \min_q u_w(p,q) = \arg\max_p \min(1-p, 2p)$$

- 解得
  - $p = \frac{1}{3}$

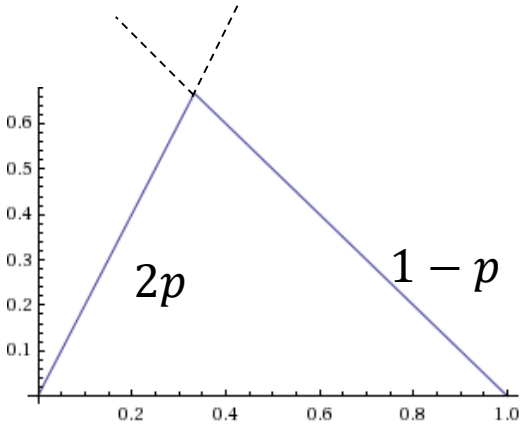

- 妻子的maxmin策略
  - 1/3概率选择韩剧，2/3概率选择体育

- 同理，丈夫的maxmin策略
  - 2/3概率选择韩剧，1/3概率选择体育

minmax策略

- minmax策略
  - 最小化对手的最大收益（收益）

$$\arg\min_{\boxed{s_i}} \max_{\boxed{s_j}} \boxed{u_j(s_i, s_j)}$$

局中人i的策略

对手j的策略

对手j的效用函数

minmax策略示例

- 性别大战
  - 妻子的策略：以概率p选择韩剧，以概率$1-p$选择体育
  - 丈夫的策略：以概率q选择韩剧，以概率$1-q$选择体育
- 丈夫的期望收益（注意：妻子的minmax策略考虑到是丈夫的收益）

$$u_h(p,q) = pq + 2(1-p)(1-q) = 3pq - 2p - 2q + 2$$

- 丈夫的期望收益关于其策略q是单调的
  - 最大值的可能取值点：$q = 0$或$q = 1$
- 丈夫的最好期望收益

$$\max_q u_h(p,q) = \max(2-2p, p)$$

- 妻子的minmax的策略为

$$\arg\min_p \max_q u_h(p,q)$$

妻子

丈夫	韩剧	体育
韩剧	1,2	0,0
体育	0,0	2,1

丈夫: h　　妻子: w

minmax策略示例

- 性别大战

$$\arg\min_{p} \max(2-2p, p)$$

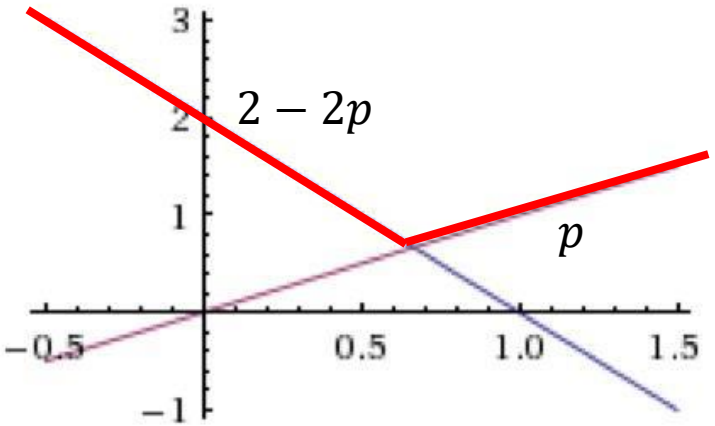

- 解得
  - $p = \frac{2}{3}$
- 妻子的minmax策略
  - 2/3概率选择韩剧，1/3概率选择体育
- 同理，丈夫的minmax策略
  - 1/3概率选择韩剧，2/3概率选择体育

maxmin策略和minmax策略

- 零和博弈情况下
  - minmax和maxmin是对偶的
  - minmax策略和maxmin策略等价于纳什均衡策略

玩家二

玩家一

	Heads	Tails
Heads	1,-1	-1,1
Tails	-1,1	1,-1

零和博弈的例子

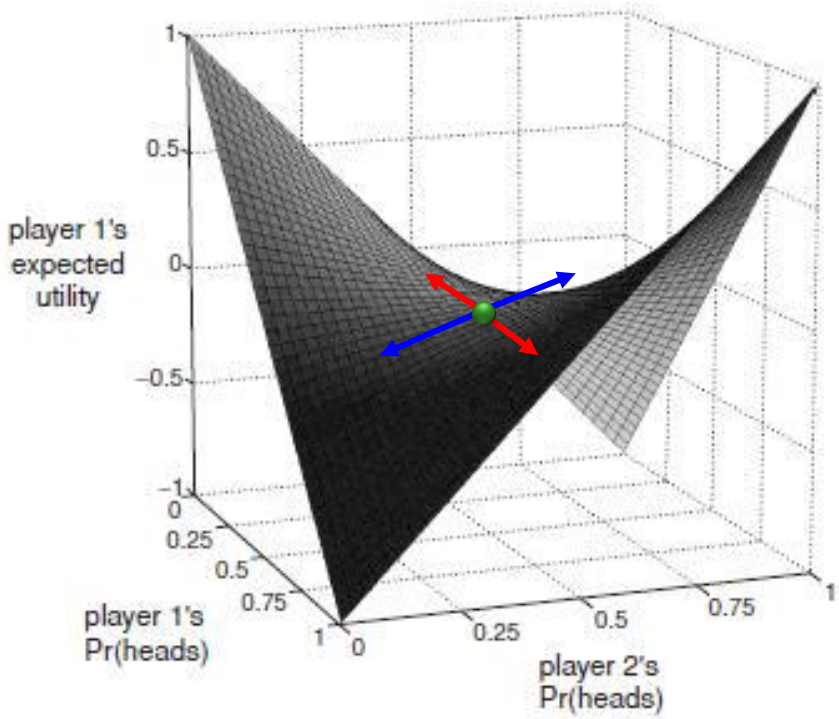

课程内容

- maxmin策略和minmax策略
- **匹配市场**
- 中介市场
- 议价权

最优匹配

- 匹配的效用
  - 成功匹配的估价之和，称为匹配的效用
- 最优匹配
  - 效用最大的匹配
- 最优匹配对于个体而言不一定最优，甚至是最差的
  - Yoram和Zoe的最优选择是Room1
  - Yoram的最差选择是Room3

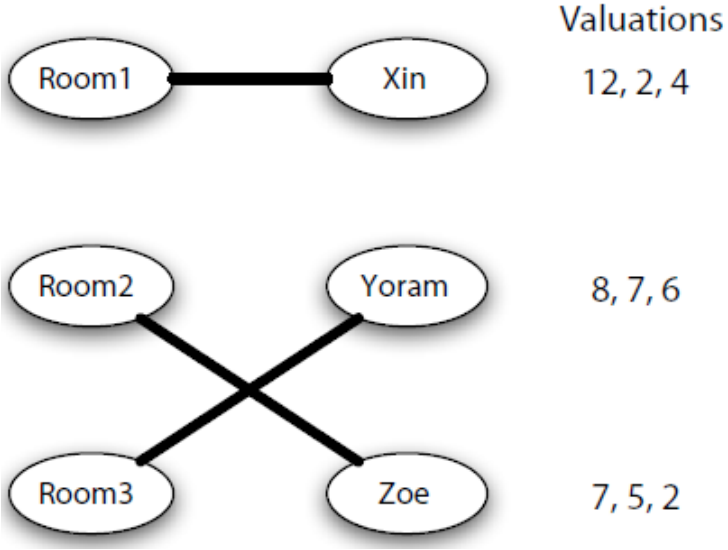

最优匹配
效用：12+6+5=23

价格导向的匹配

- 价格导向的匹配问题的形式化表示

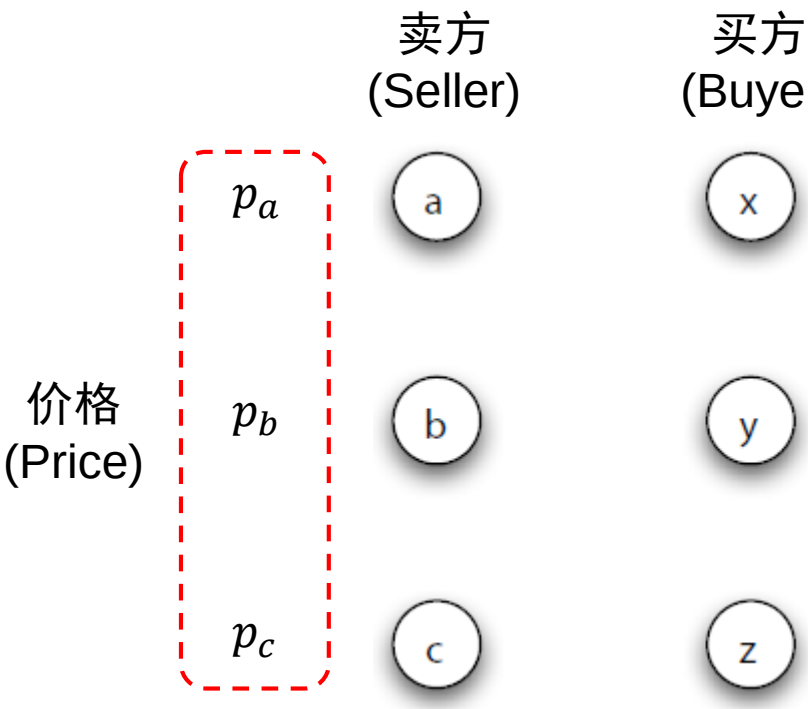

$$v = \begin{bmatrix} v_{x,a} & v_{x,b} & v_{x,c} \\ v_{y,a} & v_{y,b} & v_{y,c} \\ v_{z,a} & v_{z,b} & v_{z,c} \end{bmatrix}$$

估价
(Evaluation)

价格导向的匹配

- 估价不低于价格时，买方可以接受
  - 如果$v_{x,a} \geq p_a$，则买方x可以接受卖方a的价格，如果成交，买方x获得的效用是

$$v_{x,a} - p_a$$

  - 对于买方x，如果使其效用最大的卖方是a，那么在二部图中添加一条由x指向a的边
  - 对于同一个买方，如果有多个卖方使其效用最大，则添加多条边
  - 最终得到一个“买方偏好图”

价格导向的匹配

- 示例

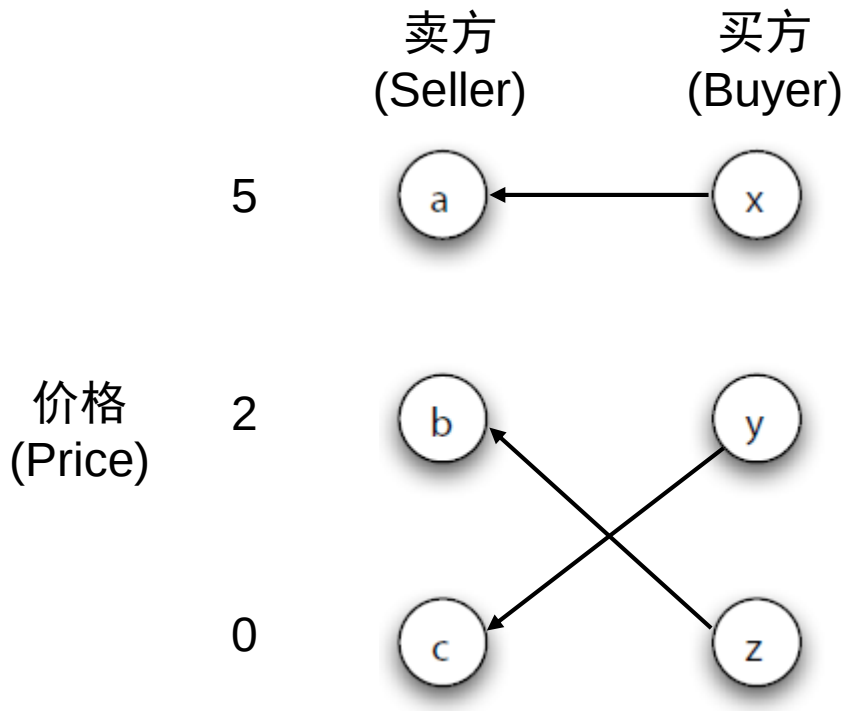

买方偏好图

估价
(Evaluation)

$$v = \begin{array}{c} \\ x \\ \\ y \\ \\ z \end{array} \begin{array}{c} \begin{array}{ccc} a & b & c \end{array} \\ \begin{bmatrix} 12, & 4, & 2 \\ 8, & 7, & 6 \\ 7, & 5, & 2 \end{bmatrix} \end{array}$$

市场结清价格

- 市场结清(Market-Clearing)
  - 每个卖方和买方都成交了

- 给定买方报价的情况下，如果卖方的某种价格使得对应的买方偏好图中存在完全匹配，则称卖方的这组价格为市场结清价格

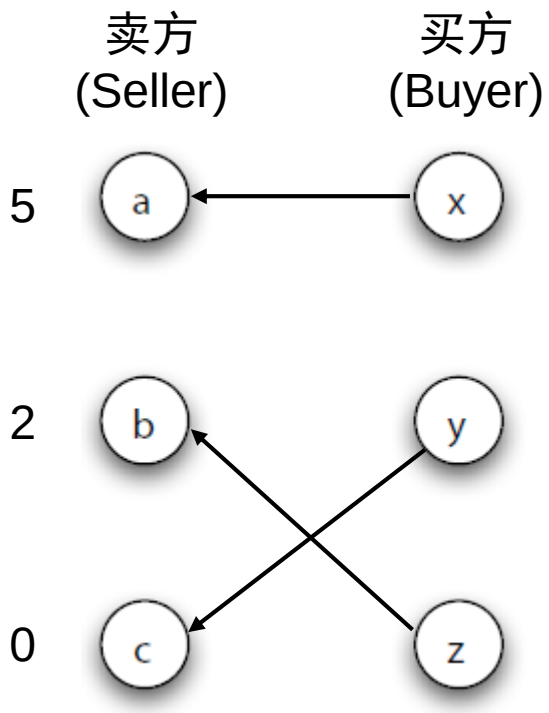

买方偏好图

市场结清价格的存在性

- 寻找市场结清价格的过程
  - 步骤1：初始时，所有卖方的价格为0
  - 步骤2：构建买方偏好图，检查其是否存在完全匹配
    - 如果存在，当前价格是市场结清价格
    - 如果不存在，从图中找到一个受限集S（一定是买方）及其邻居$N(S)$，让 $N(S)$ 中的每个卖家的价格增加1
  - 回到步骤2（当所有价格都为正时，可以通过让所有价格减去最低价格，使最低价格为0，此操作不影响结果）
- 收敛性
  - 买卖双方的总收益有限
  - $|N(S)| < |S|$，总收益下降，但不会小于0

市场结清价格

- 寻找市场结清价格的过程示例

第一轮

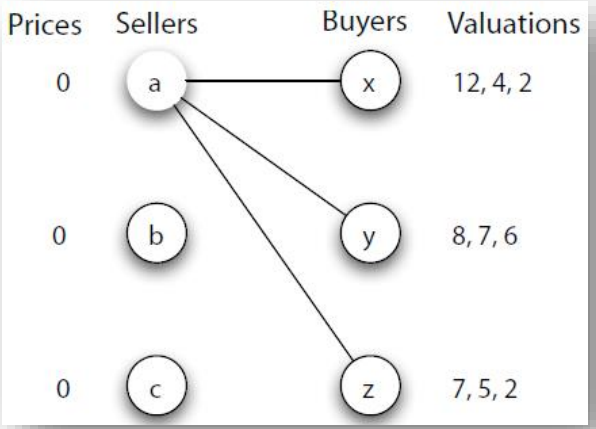

受限集S={x,y,z}，N(S)={a}

第二轮

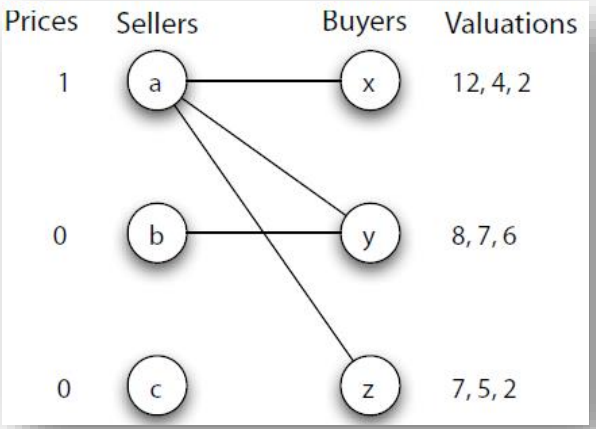

受限集S={x,z}，N(S)={a}

第三轮

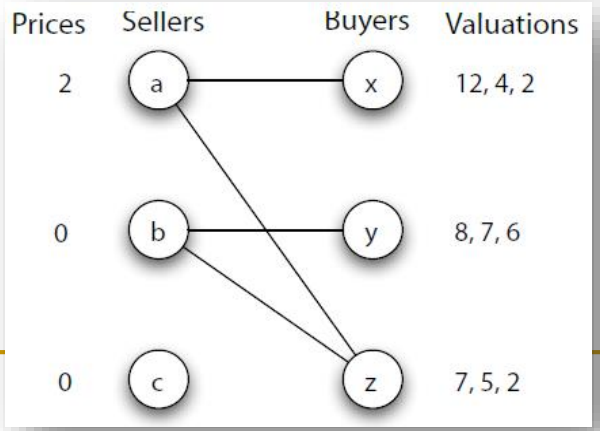

受限集S={x,y,z}，N(S)={a,b}

第四轮

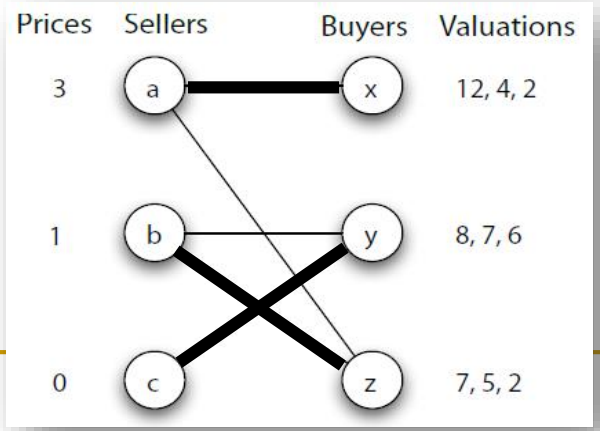

市场结清价格的存在性

- 小结
  - 完全匹配是否存在可以通过寻找受限集来判断
  - 价格能够引导市场优化配置
  - 市场结清价格总是存在
  - 市场结清价格使得买卖双方总效用最优

课程内容

- maxmin策略和minmax策略
- 匹配市场
- 中介市场
- **议价权**

网络中节点位置的重要性

- 节点在网络中所处的位置不同，导致其在博弈中的权利不同

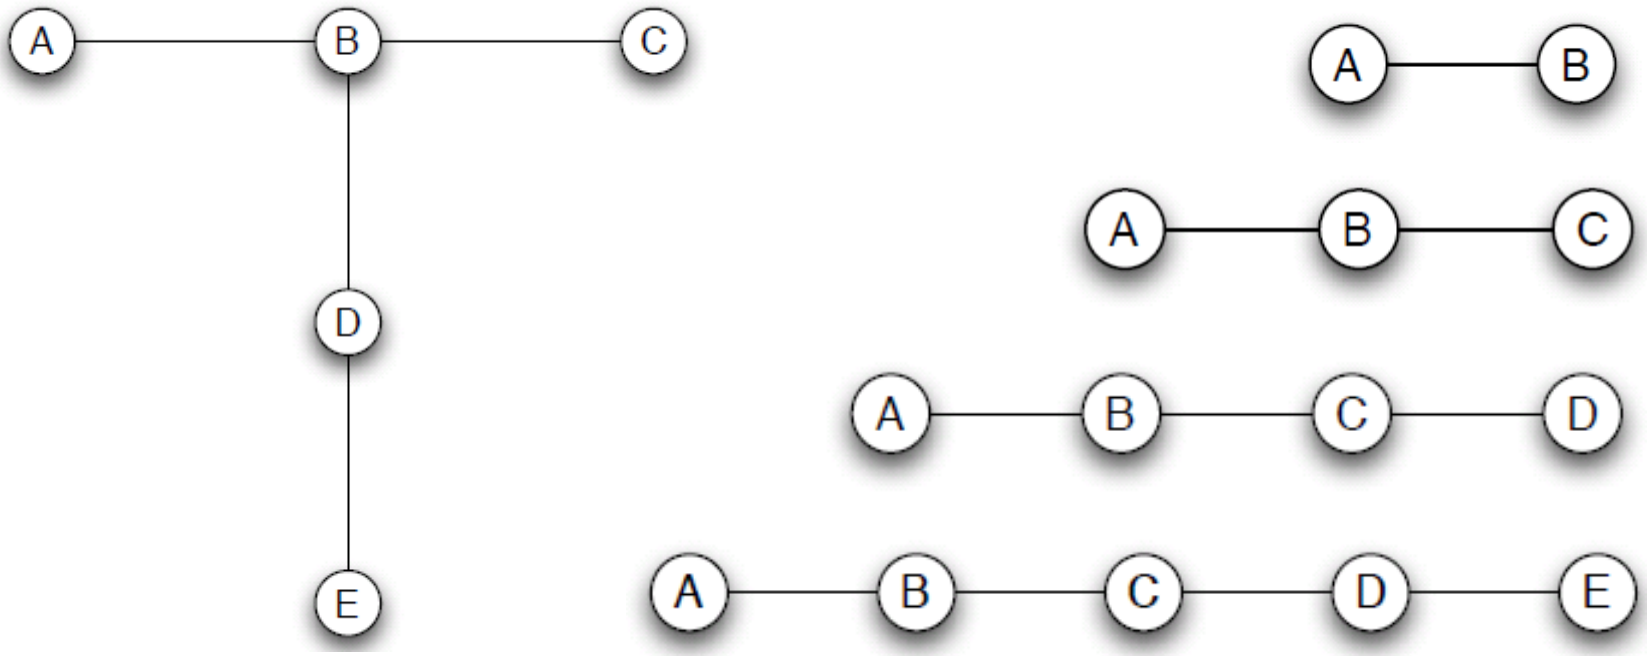

结局的稳定性

- 不稳定边
  - 对于结局中**未参与配对的边**，如果边的两个端点获得的收益之和小于1，则称这条边为不稳定边
  - 不稳定边的存在意味着其两个端点可以通过改变报价而改变结局
- 稳定结局(stable outcome)
  - 如果一个结局中不存在不稳定边，则称该结局为稳定结局

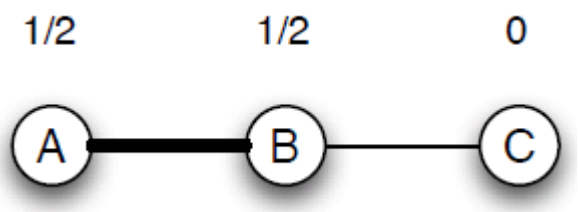

不稳定的结局
B和C的收益之和小于1

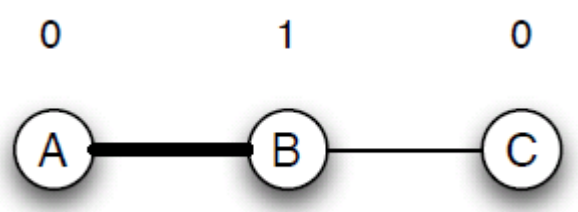

稳定的结局

结局的稳定性

- 下列哪些结局是稳定的？

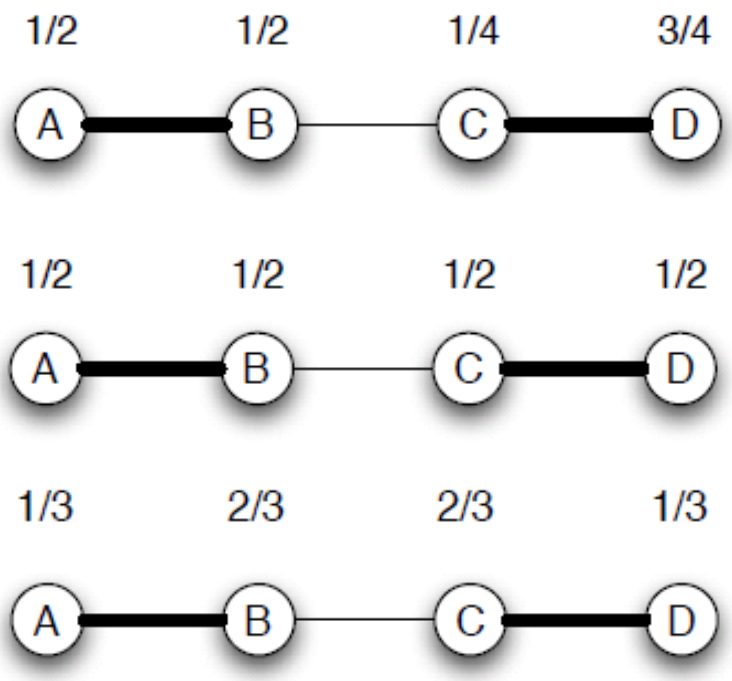

- 上面的例子中，后面两个稳定结局哪个更体现节点的议价权呢？如何判断呢？

网络中的议价权

- 有备选项的议价
  - A和B二人议价，确定分配比例
  - A的备选项收益为x
  - B的备选项收益为y
  - 要求： $x + y \leq 1$；否则A和B达不成交易

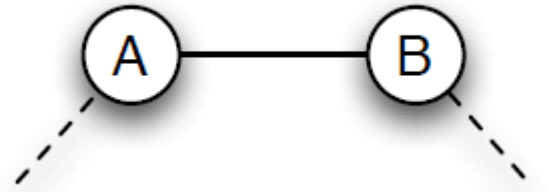

备选项 x　　备选项 y

纳什议价解

- 议价的对象
  - 如何分配“剩余价值”$s = 1 - x - y$

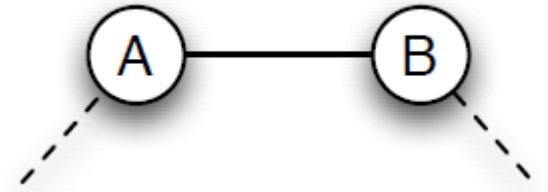

备选项 x　　备选项 y

- 纳什议价解
  - A的收益是： $x + \frac{s}{2} = \frac{1+x-y}{2}$
  - B的收益是： $y + \frac{s}{2} = \frac{1+y-x}{2}$

均衡结局

- 均衡结局（balanced outcome)
  - 给定一个结局，如果结局中的任意一个**参与配对的边**都满足纳什议价解的条件，则称该结局是均衡结局

- 注意：均衡结局一定是稳定结局
  - 因此，在寻找均衡结局时，可以先寻找稳定结局，进而确定均衡结局

均衡结局

- 下列哪些结局是均衡结局？

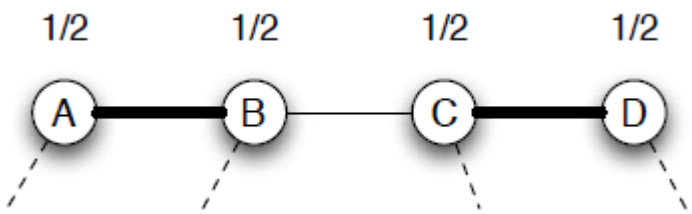

备选项0　备选项1/2　备选项1/2　备选项0

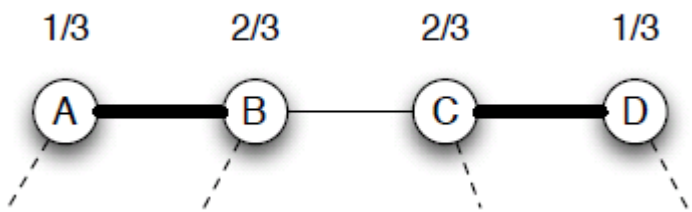

备选项0　备选项1/3　备选项1/3　备选项0

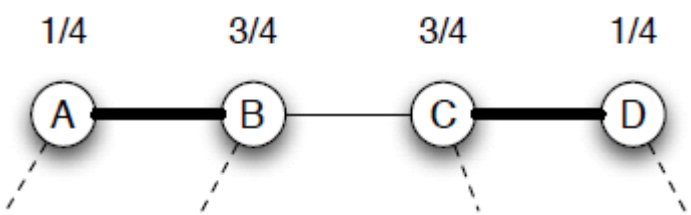

备选项0　备选项1/4　备选项1/4　备选项0

均衡结局

- 案例

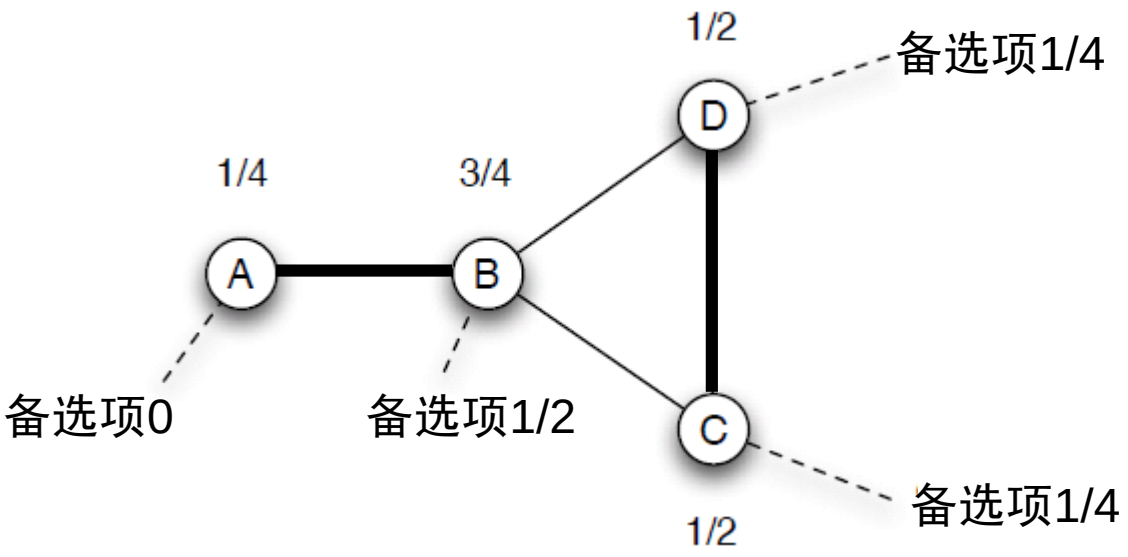

总结

- 群体智能之博弈
  - 博弈的要素：局中人、策略、效用矩阵
  - 纳什均衡策略和混合纳什均衡策略
  - maxmin和minmax策略
  - 议价和拍卖
  - 匹配问题中价格的作用
  - 纳什议价解和均衡结局

统计中的因果推断

因果模型图与独立性

- **链结构**

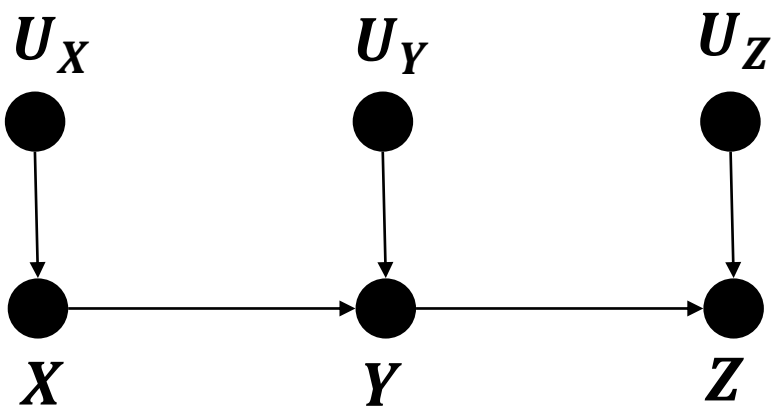

  - **例子：X——开关，Y——电路，Z——灯泡状态**

- **链结构中的条件独立性：$X \perp Z \mid Y$**
  - $X = F_X(U_X)$，$Z = F_Z(Y, U_Z)$
  - 给定 Y 时，Z 只受 U_z 影响，X 只受 U_X 影响，故X、Z 独立（已知外生变量 U_x和U_z独立）

因果模型图与独立性

- **分叉结构**

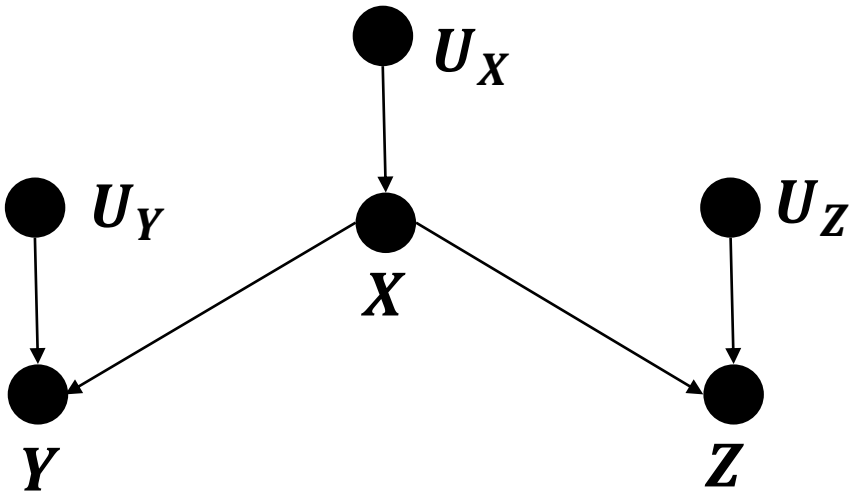

  - **例子：X——温度， Y——冰淇淋销量， Z——犯罪率**

- **分叉结构中的条件独立性： $Y \perp Z \mid X$**
  - $Y = F_Y(X, U_Y)$， $Z = F_Z(X, U_Z)$
  - 给定 X 时， Y 只受 U_Y 影响，Z 只受 U_z 影响，故Y、Z独立（已知外生变量 U_y和U_z独立）

因果模型图与独立性

- **对撞结构**

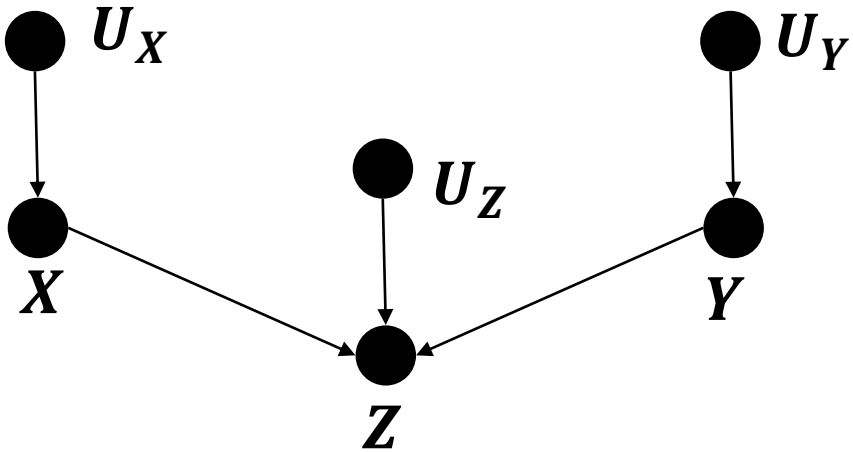

  - **例子：X——音乐天赋， Y——学业成绩， Z——奖学金**

- **对撞结构中的条件独立性： $X \perp Y$**
  - **但在给定 Z 或z的子孙时， X 与 Y 不独立（相互依赖）**
    - 某大学为两类学生提供奖学金（Z）：具有音乐天赋（X）或学业成绩优秀（Y）
    - 已知某学生获得了奖学金（$Z = 1$），如果这个人缺乏音乐天赋（$X = 0$）那么必然学业成绩优秀（$Y = 1$）

因果模型图与独立性

- d -分离用于确定因果模型图中任意一对节点是否独立

- **一条路径会被一组节点 Z 阻断，当且仅当**：
  - 路径 p 包含链结构 $A \to B \to C$ 或分叉结构 $A \leftarrow B \to C$，且中间节点 B 在 Z 中；或
  - 路径 p 包含一个对撞结构 $A \to B \leftarrow C$，且对撞节点 B 及其子孙节点都不在 Z 中。
- **如果一组节点 Z 阻断了 X 和 Y 间的每一条路径，则 X 和 Y 在 Z 的条件下是d-分离的，即$X \perp Y \mid Z$**

d —分离示例

- 以下一组变量是否能形成变量X与Y的 d —分离
  - {T} √
  - {W} ×
  - {T, U} ×
  - {T, Z} √
  - {W, U, Z} ×
  - {U, Z, T} √

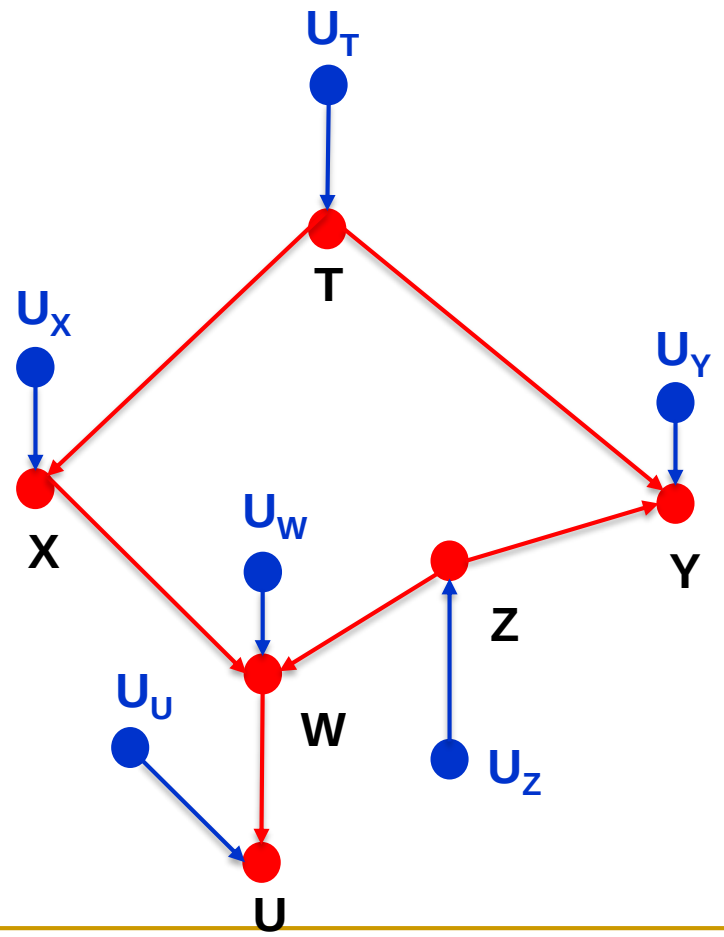

因果模型图示例

干预效果

- **平均因果效应（Average causal effect, ACE）**
  - **以服药（X）是否影响康复（Y）为例，服药对康复的因果效应差异为：**
    - $P\left(Y = \text{康复} \middle| do(X = \text{服药})\right) - P\left(Y = \text{康复} \middle| do(X = \text{不服药})\right)$
  - **传统方法：随机对照试验**
    - **控制其他变量分布一致，通过改变干预变量，观察其对结果的影响**
    - **随机对照试验成本高/有时不可行**
  - **能否从观测数据中直接估计干预效果？**
    - **校正公式！**

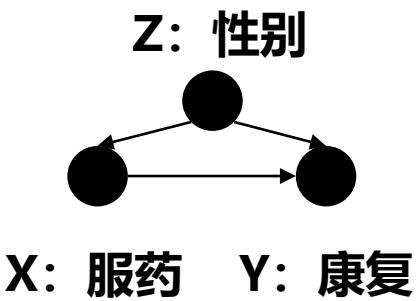

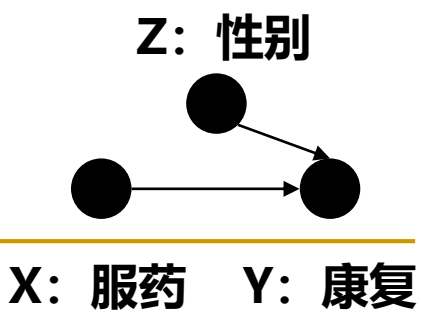

校正公式

- **校正公式**
  - **在只有观测数据的情况下，计算干预操作的效果**

$$P(Y=y|do(X=x)) = P_m(Y=y|X=x) \quad \text{（由定义）}$$

$$= \sum_z P_m(Y=y|X=x,Z=z)P_m(Z=z|X=x) \quad \text{（全概率公式）}$$

$$= \sum_z P_m(Y=y|X=x,Z=z)P_m(Z=z) \quad \text{（条件独立性）}$$

$$= \sum_z P(Y=y|X=x,Z=z)P\,(Z=z) \quad \text{（函数不变性）}$$

原因果模型图

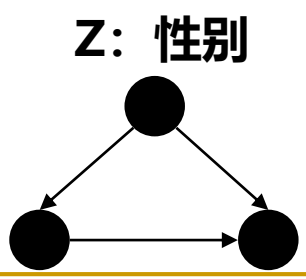

干预 X 后的因果模型图P_m

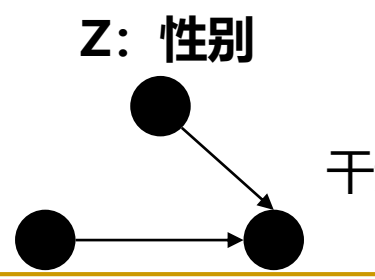

如果父节点变量不可观测怎么办？

▪ 后门准则

- **给定因果模型图中一对有序变量 (X, Y)，若变量集合 Z 满足：**
  - Z 阻断了 X 与 Y 之间的每条含有指向 X 的路径
  - Z 中没有 X 的后代节点

则称 Z 满足关于(X, Y)的后门准则

▪ 后门校正

- **若变量集合 Z 满足 (X, Y) 的后门准则，那么 X 对 Y 的因果效应可由以下公式计算：**

$$P(Y = y|do(X = x)) = \sum_z P(Y = y|X = x, Z = z)P(Z = z)$$

直观理解后门准则

▪ 后门准则

- **给定因果模型图中一对有序变量 (X, Y)，若变量集合 Z 满足：**
  - Z 阻断了 X 与 Y 之间的每条含有指向 X 的路径
  - Z 中没有 X 的后代节点

1. 阻断X和Y之间的后门路径
2. 保持从X到Y的因果路径不变

则称 Z 满足关于(X, Y)的后门准则

例子：

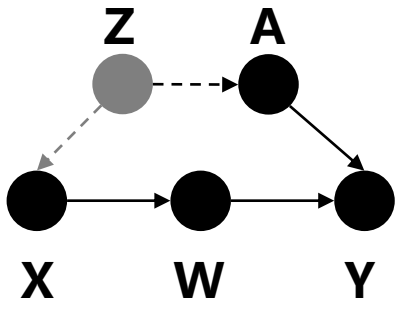

$$P(Y = y|do(X = x))$$

1. 变量集合希望阻断可能使X和Y存在“伪因果”的后门路径，例如 $X \leftarrow Z \rightarrow A \rightarrow Y$

2. 变量W不应该被包含在集合Z中

- **一条路径会被一组节点 Z 阻断，当且仅当：**
  - 路径 p 包含链结构 $A \rightarrow B \rightarrow C$ 或分叉结构 $A \leftarrow B \rightarrow C$，且中间节点 B 在 Z 中；
  - 路径 p 包含一个对撞结构 $A \rightarrow B \leftarrow C$，且对撞节点 B 及其子孙节点都不在 Z 中。

该因果模型图中变量 A 满足关于(X, Y)的后门准则

例子：满足后门准则的变量集

- 找出满足变量对 (X, Y)的后门准则的变量集

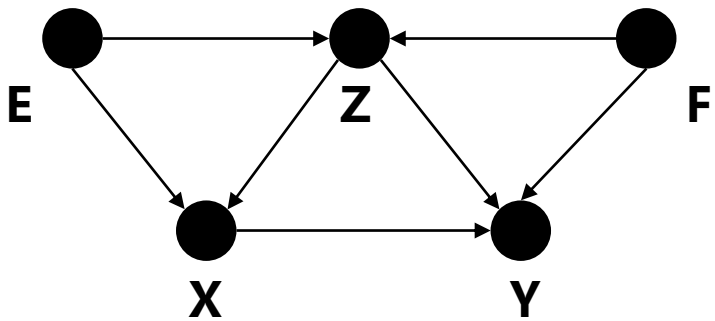

- {Z} ×
- {E, Z} √
- {F, Z} √
- {E, F} ×
- {E, F, Z} √

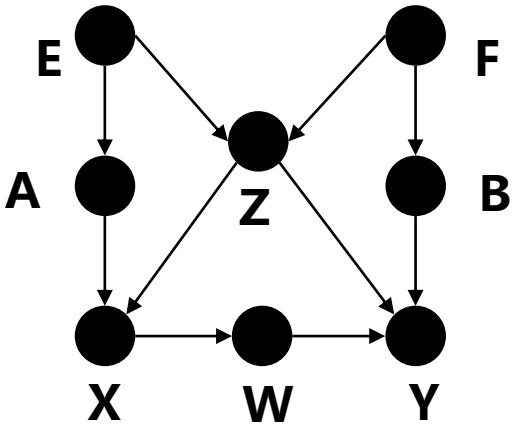

- {Z} ×
- {F, Z} √
- {A, Z} √
- {W, A, Z} ×
- {A, F, Z} √